CrossExam 质询室

> 全国高校 Vibe Coding 开发挑战赛 · AI 创新应用挑战赛（赛道 10039） 技术文档 —— 意图控制策略 / 架构设计 / 可复现性论证

多 Agent 对抗式面试沙盘：把简历里那句你其实答不上来的话，在投出去之前找出来。

项	内容
作品名称	CrossExam（质询室）
仓库	见 README 顶部（公开仓库，细粒度提交，共 120 余次）
技术栈	Node 24 + TypeScript（服务端零构建）· Hono + SSE · node:sqlite · Vite + React 19 + Tailwind v4
交付日期	2026-11-18（省赛作品提交截止）
文档版本	1.0 · 2026-10-26
演示前提	不需要 API Key、不需要数据库、不需要 Docker，一条命令起完整产品

本文档怎么读

这份文档不是功能说明书，它只回答评委评分表上的三个问题：

评分维度	权重	对应章节
过程可复现性与演进链路	25%	第四章（可复现性论证）、第五章（实测证据）
方法创新性与意图控制	20%	第二章（意图控制策略）
工程质量与架构设计	15%	第三章（架构设计）
解题有效性与实用价值	25%	第一章（问题定义）与第五章（真实模型实测）
用户体验与产品精细度	15%	3.8 节（前端形态）与第五章（真浏览器实测）

三条阅读路径，按可用时间自选：

1. **只有 5 分钟**：读第一章的 1.3 与 1.4，再看第二章的 2.2 那张四层表。
2. **想验收**：直接跳第五章，那里全是可复跑的命令与实测数字。
3. **想审设计**：第二章讲「怎么让模型听话」，第三章讲「为什么这么切模块」，第四章讲「凭什么说它可复现」。

文中所有数字都来自本机实测或仓库内的可复跑命令，来源标在数字旁边； 没有实测支撑的判断会明确写成判断，而不是伪装成结论。

第一章　问题定义：简历里那句话，你答不上来

1.1 一个具体的失败场景

求职者张明（本文档全程使用的示例人物）简历上写着两句话：

> 主导重构订单系统，首屏加载从 2.4s 降到 0.8s。 主导引入 Redis 缓存，QPS 从 800 提升到 5000。

他投出去，进了面试。面试官问：「2.4s 到 0.8s，怎么测的？取的均值还是 P75？样本量多少？」

张明答不上来。他确实做过这个优化，但那个数字是同事报给他的；他没测过，也不记得口径。 于是面试官得到两个结论：这个人对数字不负责；这份简历不可信。

问题不在于他会不会写代码，而在于简历上的每一个数字，都是一个等待被追问的主张，而他没在被追问之前演练过。

这个场景有三个关键性质，直接决定了产品形态：

性质	含义	对产品的约束
主张是可枚举的	一份简历能抽出 5–12 条「可被追问的主张」	不需要做通用对话，做「逐条质询」就够
追问是有方向的	面试官不会随机问，他们拆口径、拆归属、拆因果	追问策略可以被写成可复用的意图契约
反馈必须可执行	「你答得不好」没有价值，有价值的是「这句话改成什么」	输出必须回落到简历原文的具体片段

1.2 现有方案为什么不够

市面上的简历工具分三类，各自缺一块：

类型	代表	它能做什么	它不能做什么
简历生成 / 美化	各类在线简历编辑器	排版、模板、导出	不检验内容是否站得住
AI 润色	通用大模型对话	把句子写得更好看	会替你编，且编得比原文更自信
模拟面试	题库式 / 通用 AI 面试官	出题、打分、给建议	不锚定你的简历原文，问题与你写的东西无关

第三类是最近的形态，也是本项目的近邻。它的核心缺陷可以用一句话说清： **它的提问不携带证据。** 面试官问「谈谈你最有挑战的项目」，这句话对任何人成立， 因此它对任何人都不成立——它无法指出你简历里哪一句话站不住。

1.3 CrossExam 的解法：把「面试」变成「逐条主张的证据审计」

CrossExam 的输入是**一份简历 + 一份目标岗位 JD**，输出是**每条主张的判定 + 回落到原文的修改建议。** 中间的过程是 3–5 位人设不同的 AI 面试官，对每条主张并发追问。

一场完整的质询有五个阶段，全部由程序编排、全部可回放：

```
简历 + JD
   │
   ├─ ① 抽取主张   extract   从简历里抽出可被追问的主张，每条必须携带逐字引文
   │                         锚不到原文的主张当场丢弃（不是降级，是丢弃）
   │
   ├─ ② 并发追问   probe     3 位面试官按各自的意图契约同时提问
   │                         每轮：预算闸门 → 锚定闸门 → 去重闸门
   │
   ├─ ③ 求职者作答 answer    求职者 Agent 只能引用简历原文作答，编造的引文被丢弃
   │                         连续答不上来 → 该主张自动关停（不再浪费追问）
   │
   ├─ ④ 判定       verdict   每条主张给出：站得住 / 表述过度 / 证据缺失 / 与原文矛盾 / 无法回答
   │                         两条代码级收敛：全没答上来又判站得住 → 证据缺失；要证据却拿不出 → 证据缺失
   │
   └─ ⑤ 改写建议   suggest   把「答不上来」翻译成「这句话该怎么改」
                             四道闸门：改前原文必须定位得到、不许引入新数字、不许等于原文
```

五种判定不是设计出来的修辞，而是**证据审计的五个可能结论**：

判定	含义	触发条件（产品语义）
站得住	主张有原文支撑，且追问下给出了可核验的口径	答得上 + 能援引原文
表述过度	主张本身没错，但说法超出了证据能支撑的范围	答得上但暴露了口径不一致
证据缺失	主张可能成立，但拿不出任何可定位到简历的证据	模型判定（责任在简历写法）；或模型判 solid/contradicts 却给不出引文 → 代码降级
与原文矛盾	追问下的回答与简历原文冲突	回答援引的原文与主张指向的事实相反
无法回答	候选人被追问后明确表示拿不出、不记得、没做过	模型判定（责任在人，风险最高的一类）

1.4 与近邻产品的差异（不是形态差异，是判断依据的差异）

赛题明确禁止「直接使用已有开源项目包装参赛」，因此这里做的是**能力对照**而不是功能对照。 本项目在立项时研究过一个成熟的同类产品（本地优先的 AI 求职工作台，Apache-2.0，545 次提交，7 个主模块）， 它把「防编造」做在了**生成侧**：维护一份用户核实过的事实台账，只有核实过的事实才允许进入生成。

维度	事实台账式（生成侧防编造）	CrossExam（质询侧做压力测试）
触发时机	写简历之前	简历写完之后、投出去之前
核心动作	拦截：不许写没核实过的事实	质询：写下的话经不经得起追问
输出物	一份更安全的简历	一份带判定与改写建议的审计报告
对模型的要求	不许发挥	必须发挥（扮演不同面试官施压）
失败模式	台账太严，简历写不出来	追问太空，等于没问

两者的关系是互补而不是重叠：台账保证「写下来的都是真的」， 质询保证「写下来的都答得上」。本项目选择后者，因为它有一个前者没有的性质： **追问是可以被证伪的**——一次提问如果锚不到简历原文，它就是一个可以被程序判定为无效的提问。 这条性质是第二章全部意图控制手段的起点。

1.5 谁会用、用在什么时候

用户	场景	得到的价值
应届生 / 转行者	简历投出去石沉大海，不知道问题在哪	在投递前发现「这句我答不上来」
有经验但久未面试的人	项目是两年前做的，细节忘了	被追问后知道该补哪段记忆、该改哪句话
简历辅导 / 就业指导老师	批量看学生简历	一份可下载的审计报告，指出具体句子
面试教练 / 训练营	做模拟面试	用不同人设反复施压，且过程可复现

它不是「AI 帮你写简历」，而是「AI 帮你找出简历里最脆的那一句」。 这个定位带来一个直接的产品约束：**报告必须定位到字。** 「你的项目描述不够具体」是无效反馈；「第 81–108 字这句『首屏加载从 2.4s 降到 0.8s』答不出测量口径，建议改为……」才是有效反馈。

1.6 本章要点

- 问题是「简历上的数字经不经得起追问」，不是「简历写得好不好看」。
- 因此产品形态是逐条主张的质询，不是通用对话。
- 因此每条提问必须携带简历原文锚点——这是可证伪性的来源。
- 因此输出必须回落到原文的具体片段——这是实用价值的来源。

第二章　意图控制策略

赛题把 20% 的权重给了「方法创新性与意图控制」。这一章要回答的问题很具体：

> 当你有 3 个 Agent 在同一个沙盘里各自发挥时，**你凭什么说它们在你的意图之内行事？**

2.1 「在提示词里写要求」不是意图控制

大多数多 Agent 产品的控制手段是：在 System Prompt 里写一段要求，然后相信模型会遵守。 例如「每条提问最多追问 3 次」「你的提问必须来自简历原文」。

这在工程上是不成立的，理由是**提示词是建议，不是约束**：

你写的	模型实际可能做的	后果
「最多追问 3 次」	第 4 次继续问	死循环，烧钱，演示卡死
「提问要来自简历原文」	编一段听起来像简历的话	幻觉式提问，用户被问懵
「一次只问一个问题」	问三个连在一起	用户不知道答哪个
「答不上来就停止追问」	继续换角度施压	用户被反复羞辱同一件事

更麻烦的是：**这些违规不会报错。**模型会返回格式完全合法的 JSON， 里面装着一条越界的提问；如果你只校验 JSON 结构，它会一路通过，直到用户看见。

所以 CrossExam 的设计原则是：

> **凡是可以被程序判定的约束，就不要交给模型自觉。** 模型负责「想出好问题」，程序负责「保证这个问题合规」。

2.2 四层意图控制：从声明到收敛

本项目把意图控制拆成四层，每层有明确的职责边界与失败表现。

层	名字	做什么	在哪实现	被拦下时用户看到什么
L1 声明	意图契约 Intent Contract	每个 Agent 的 System Prompt 是结构化 JSON，可解释、可版本化、可 diff	`packages/shared/src/contract.ts`	界面上可展开查看契约全文与指纹
L2 校验	结构 + 锚定	模型输出必须过 zod schema；每条提问的引文必须能在简历里逐字定位	`packages/shared/src/schemas.ts`、anchor.ts	被拦下的提问列在「被拦下的追问」里，附原因
L3 记账	追问预算 Probe Budget	追问次数由代码记账，不是由模型数数	`packages/shared/src/budget.ts`	主张卡片上出现「已关停」与关停理由
L4 收敛	判定与建议的代码级收敛	模型给的判定与建议还要过一遍确定性规则	`packages/server/src/orchestrator/verdict.ts`、suggest.ts	判定卡片上标注「这条判定不是模型直接给的」

这四层的顺序很重要：**先声明，再校验，再记账，最后收敛。** 每一层都只依赖上一层已经确定的产物，因此整条链路是确定性的、可单测的、可在离线模式下复现的。

2.3 L1 声明层：意图契约是数据，不是文案

2.3.1 结构

每个面试官 Agent 的行为由一个结构化对象完全决定，而不是一段散文式提示词：

```
{
  "id": "tech",
  "version": 1,
  "persona": {
    "name": "技术面试官",
    "role": "tech",
    "seniority": "senior",
    "tone": "skeptical",
    "blurb": "资深工程师，冷静、只问细节"
  },
  "goal": "验证简历里的技术栈与项目描述是否真的出自本人之手，还是只写过 demo。",
  "tactics": [
    "追问技术选型的原因，而不是「用了什么」",
    "追问具体的失败与返工",
    "把简历里的一个数字拆开问口径"
  ],
  "constraints": [
    "每次提问必须携带能从简历里逐字找到的 quote",
    "引文至少 4 个字符",
    "一次只问一个问题",
    "只问简历里写过的东西，不要新造主张"
  ],
  "forbidden": [ ... ],
  "budget": {
    "maxRoundsPerClaim": 3,
    "maxProbesPerInterviewerPerClaim": 2,
    "maxTotalProbes": 60
  }
}
```

（以上为真实数据，来自 `PERSONA_PRESETS` 经 `buildContracts(['tech'], ...)` 生成， 技术面试官契约的指纹是 `042b385f925cf50f`，HR 是 `2375be34602e49f3`，业务主管是 `b2ed25a1d9d3995a`。）

2.3.2 为什么必须结构化

好处	具体表现
可解释	界面能把「它被允许做什么、被禁止做什么」摊开给人看，不用猜
可版本化	`version` 字段 + 内容指纹，改一个字指纹就变
可 diff	契约是 JSON，两次改动之间能看出改的是 tactics 还是 forbidden
可对账	库里只存 `{id, version, digest}`，读侧按同样输入重算，指纹不一致就显示「契约已漂移」
可渲染	System Prompt 由 `renderSystemPrompt(contract)` 确定性渲染，同样契约永远得到同一份提示词

第 4 条是本项目的一个明确取舍，也是设计上最值得讲的一处。

2.3.3 契约不落库全文，只落指纹

要做「契约可见」，最省事的做法是把契约 JSON 存进会话表，读出来显示。本项目没有这么做。

库里只存三样：

```
{ id: 'tech', version: 1, digest: '042b385f925cf50f' }
```

读侧每次按同样输入（面板 + 预算）**重新计算**契约全文，再用指纹与库里那一份对账：

```
const verified = match !== undefined
  && match.digest === digest
  && match.version === contract.version;
```

理由是「存副本」会把一句无法验证的断言混进产品：代码改了契约之后，老会话显示的仍是旧副本， 而旧副本已经不在任何地方运行了——**观众看到的和实际跑的不是同一份东西，且没有任何信号提示。**

重算 + 对账把这件事变成可判定的状态。界面上只有两种结论：

状态	界面文案	含义
一致	与运行时一致 · 指纹 b2171c82	现在这份契约就是跑这一场时用的那份
漂移	契约已漂移 · 运行时 a1b2c3d4 → 现在 b2171c82	代码改过契约，这场会话用的是旧的
未开跑	尚未开跑 · 当前指纹 b2171c82	还没跑，无从对账

这个取舍的一般化结论写在 `findings.md` 的 F19 里： **凡是「实现里有一份、展示里又抄一份」的数据，都该改成「一份真值 + 一个指纹」。**

2.3.4 契约的渲染：System Prompt 的六节结构

模型实际拿到的不是上面那段 JSON，而是由它确定性渲染出的六节提示词。以技术面试官为例（真实输出，界面截图 10-system-prompt.png 就是它）：

节	作用	是否可被程序校验
你这一场的目标	告诉它「为什么问」	否（属于意图）
可用手法	给出三条具体战术，避免泛泛而问	否
硬约束（由程序强制校验，违反的提问会被丢弃）	四条必须满足的条件	**是**（L2 锚定 + 去重）
禁止	四条禁区	部分
追问预算（由程序记账，你不需要自己记）	三条上限	**是**（L3 记账）
输出要求	精确的 JSON 形状	**是**（zod）

注意「硬约束」与「追问预算」两节的标题措辞：它们明确告诉模型「这件事由程序负责」。 这不是修辞——它减少了模型在边界上的试探，因为模型知道越界会被直接丢弃，而不是被商量。

2.4 L2 校验层：证据锚定，让提问可证伪

2.4.1 规则

每条提问必须携带一个 `quote`，它是**从简历里逐字复制的片段。**程序做三件事：

1. 先做逐字查找（`source.indexOf(quote)`），命中即 `exact: true`；
2. 失败则做归一化查找（全半角标点映射 + 空白折叠 + 小写），命中则 `exact: false`；
3. 两者都失败 → 这条提问被丢弃，理由写进「被拦下的追问」，**不消耗预算。**

锚点的坐标由程序用 `source.slice(start, end)` 算出来，**不采信模型给的 start/end。** 这条决定记在决策表 D7：模型给的偏移量只当提示，坐标以引文回原文重新定位为准。

2.4.2 四种拒绝理由

拒绝码	中文标签	触发条件
empty-quote	引文为空	模型没给 quote
too-short	引文太短	少于 4 个字符（短引文能在简历里命中任何地方，等于没锚定）

拒绝码	中文标签	触发条件
quote-not-found	引文在简历里找不到	模型改写了原文、补了标点、或编了一句
out-of-range	区间越界	计算出的区间超出简历长度

2.4.3 为什么这条规则是全部创新点的地基

「提问必须锚定原文」把一句主观判断（这个面试官问得好不好）变成了一句客观判断（**这个问题有没有证据**）。 它带来三个连锁效果：

- **幻觉式提问被物理消灭**：模型编一句「你在某大厂做过高并发」是过不了锚定的，因为简历里没有这句话。
- **界面可以拒显**：没有锚点的提问不会进入事件日志，因此也不会进入界面。
- **追问变得可评估**：每条提问都指向一个具体的简历片段，因此「这条主张被问了几次、问到什么程度」是可统计的。

第三个效果直接引出下一层。

2.5 L3 记账层：追问预算，让死循环在设计上不成立

2.5.1 问题

多 Agent 追问最常见的失败形态是**不收敛**：A 问完 B 换个角度问，B 问完 A 再追一层， 每一轮都「还有可以问的」，于是永远停不下来。提示词里写「最多 3 次」拦不住它。

2.5.2 做法

把追问次数做成一个**不可变的账本**（`packages/shared/src/budget.ts`），每次提问前必须过闸门，通过才记账：

```
export interface BudgetConfig {
  maxRoundsPerClaim: number;              // 同一条主张全场最多追问几轮
  maxProbesPerInterviewerPerClaim: number; // 每位面试官对同一条主张最多问几次
  maxTotalProbes: number;                  // 全场追问总次数上限
  maxConsecutiveUnanswerable: number;      // 连续几次答不上来就关停这条主张
}

export const DEFAULT_BUDGET: BudgetConfig = {
  maxRoundsPerClaim: 3,
  maxProbesPerInterviewerPerClaim: 2,
  maxTotalProbes: 60,
  maxConsecutiveUnanswerable: 2,
};
```

闸门 `canProbe(state, claimId, interviewerId)` 按固定顺序做五道检查，**任何一道不过就拒绝，并给出可直接展示给用户的中文理由**：

顺序	检查	拒绝理由（原文）
1	主张是否存在	该主张不在本次沙盘中
2	主张是否已关停	关停理由，或「该主张已关停」
3	全场总次数	已达全场追问上限 60 次
4	该主张轮数	该主张已达追问轮数上限 3 轮
5	该面试官额度	该面试官对这条主张的提问额度已用完

顺序不是随意的：先判「这条主张还值不值得问」，再判「全场还有没有预算」，最后才判「这位面试官还有没有额度」。这样拒绝理由总是最有信息量的那一条。

2.5.3 关停：连续答不上来就止损

账本还负责一件事：如果求职者连续 2 次答不上来同一条主张，这条主张被自动关停，理由写进账本：

> 已连续 2 次答不上来，继续追问没有信息增量

关停之后这条主张从「可追问清单」里消失（简历原文当然还是整份给模型），后续轮次不会再为它发起调用。 这条规则同时解决了两个问题：用户体验（不反复羞辱同一件事）与成本（不为已知结论烧 token）。

2.5.4 编排层的收尾条件

编排循环的条件是：

```
while (rounds < maxRounds && probeableClaims(budget, panel).length > 0) { ... }
```

这里有一个容易写错的地方值得写进文档：一开始用的是 `openClaims(budget).length > 0`， 而 `openClaims` 只表示「主张没有被 close」——额度用尽的主张仍然算 open，于是编排器会白烧一轮空的模型调用（live 模式是真金白银）。 为此新增了 `probeableClaims(state, interviewerIds)`：**存在至少一位面试官能通过 `canProbe` 的主张。**

另外，如果一轮下来所有面试官都没有提出任何新问题（都被去重闸门拦了），编排器直接收尾并写一条如实记录的提示：

> 第 3 轮没有任何新的追问，质询到此结束

这条提示会出现在报告里，也会出现在界面的事件日志里——**收敛是可见的，不是悄悄结束的。**

2.6 L4 收敛层：模型给的判定与建议，还要再过一遍代码

2.6.1 判定阶段的两条收敛规则

模型判完之后，`enforceVerdict` 会用两条确定性规则复核（`verdict.ts`）：

规则	条件	处理	理由文案
全没答上来还判「站得住」	有追问，所有追问的回答都无效，且模型判「站得住」	降级为「证据缺失」	候选人对这条主张的追问没能落出口径，原文这一句不足以判为「站得住」，按「证据缺失」处理
要证据却拿不出	判为「站得住」或「与原文矛盾」，但证据引文一条都定位不到	降级为「证据缺失」	模型判为「站得住」但模型拿不出可定位到简历原文的证据，按「证据缺失」处理

第二条尤其重要：**「站得住」是一个需要证据的结论。**模型想判 solid，就必须拿出能在简历里定位到的引文； 拿不出，这个判定就不成立。这与 L2 的锚定是同一个思想，只是从「提问」延伸到了「结论」。

第一条只做一件事：**防止过于乐观**，而不是替模型决定责任归属。代码手里只有一个布尔（这一场有没有答上来过）， 而模型看得见每一轮问答——它比这个布尔更清楚该算「简历写得太笼统」（证据缺失，改简历就行）， 还是「候选人自己拿不出东西」（无法回答，风险最高）。把「全体未答」一律改判「无法回答」的版本犯过一个真实错误： 模型的理由里明明白白写着「只有结论、没有口径，属证据缺失」，界面上却挂着「无法回答」的徽章—— 理由是模型写的，结论是代码改的，两者当场矛盾（真实联网运行时才发现，见 5.6 第 5 条）。

为了让这两档可判别，`VERDICT_SYSTEM` 把判据写成了**责任在谁**：证据缺失 = 简历的错（这句话写得太笼统， 改法是把口径写进去）；无法回答 = 人的错（本人承认不记得、举不出例子、没做过，面试现场会直接翻车）。 拿不准时判「证据缺失」——它是一个可执行的结论，指向改简历；误判「无法回答」会让人以为这段经历该删掉。

被代码改过的判定会在界面上带一条琥珀色说明：「这条判定不是模型直接给的」+ 具体理由。 截图 06-verdicts.png 里的 C5 就是这种情况。

2.6.2 建议阶段的四道闸门

改写建议是最容易被模型「发挥」的环节——它会顺手帮你加一个更漂亮的数字。 因此 `suggest.ts` 设了四道闸门，任何一道不过，这条建议被拒绝并记录原因：

闸门	检查	拒绝理由
是否需要建议	判定为「站得住」的主张直接跳过（不调用模型、不消耗预算）	判定为「站得住」，不需要改写
改前原文可定位	`before` 必须能在简历里锚定到	建议里的「改前原文」在简历中定位不到，无法应用
不许引入新事实	`after` 里的数字必须是简历里已有的数字	建议里出现了简历原文中不存在的数字，属于新增事实
必须真的改	`after` 不能为空，也不能等于 `before`	建议改写后与原文相同，等于没改

第二道闸门的具体实现是 `newNumbersIn(after, resumeText)`：用正则 `/[0-9]+(?:\.[0-9]+)?/g` 抠出建议里的所有数字，逐个检查是否在简历原文的数字集合里出现过；只要有一个新的，整条建议作废。

这条规则的效果可以在离线演示里直接看到：C2 的改写建议里出现的 `800` 与 `5000` 都来自简历原文， 模型没有机会把「QPS 5000」改成「QPS 8000」。

2.6.3 归属由调用方决定

建议的归属（这条建议属于哪条主张）**一律由调用方传入**，模型自报的 `claimId` 不看。 这一条在 live 实测里救过一次命：schema 曾把 `claimId` 列为必填，而提示词从没要求模型输出它， 于是 9 条建议全部因「claimId: Required」被拒；离线演示恰好写了这个字段，把矛盾完整掩盖。 修复后 `claimId` 改为 optional，并补了「模型不返回 claimId 也能出建议」的回归测试。

这个 bug 的教训写在 `findings.md` F23，也是本文档第 5.6 节要展开的「给模型输出造夹具的唯一真相是提示词里的输出要求」。

2.7 过程可视化：流式分片是观感，事件日志才是真相

赛题的 UX 评分项明确点名了「流式、思考可视化」。本项目的处理方式是一条明确的分界：

	流式分片	阶段事件
内容	模型正在吐的字符	阶段开始 / 主张列表 / 追问列表 / 判定列表
落库	**否**	是（带 seq）
可断线续传	否（刷新就没了）	是（`?from=<seq>`）
界面位置	卡片内的「正在作答」「正在定级」+ 过程面板的「实时输出」	阶段时间线

实现方式是给 LLM 客户端套一层 `withStreaming(inner, sink)`：五个阶段的编排代码照旧 `await client.complete()`，包装层把它改写成 `for await (inner.stream(req))`，把 `delta` 与 `reasoning` 分片送进 sink，最终结果取自 `done` 事件。 分片通过 SSE 的 `event: stream` 送出，**不带 id、不占 seq、不进事件表。**

理由写在 ADR-0004 里：分片每秒几十片，落库会让回放变慢、日志变吵，而分片拼出来的文本并不比 done 事件更可信。 **能断线续传的只有阶段事件——这是「可复现」与「好看」之间的一条明确分界。**

顺带一个工程细节：分片携带的 `channel` 字段（例如 `answer:P1`、`verdict:C3`）**刻意不参与卡带指纹**， 因为指纹只对请求做哈希（system / messages / temperature / maxTokens / json）。 这条设计让「加流式」这件事不需要重录任何一盘离线卡带。

2.7.1 思考分片：接上会思考的模型，界面上多一行斜体

思考（`reasoning`）与正文（`delta`）是两个独立通道，用分片上的 `kind` 区分；界面渲染成两行—— 斜体那行是它正在「想」的，正下方那行是它要「说」的。要让这一行真的出现，需要三件事：

环节	做法	为什么
选谁思考	装配层 `withStageModels(inner, routes)`，按 `req.purpose` 换模型	判定才需要「停下来想」；追问一轮十几次调用，全交给思考模型会把一场从十几秒拉成几分钟（ADR-0005）

环节	做法	为什么
换模型不发卡带	`LlmRequest.model` 与 `channel` 一样不参与指纹	已录好的 29 盘演示卡带不必重录
没有 Key 也看得见	合成脚本把 `reasoning` 写进卡带（同一个通道）	离线演示也要能证明「思考可视化」是产品能力，不是联网才有的彩蛋；卡带 `model` 固定 `scripted-demo`，一眼可辨

实测（2026-10-26，示例简历，`CROSSEXAM_REASONING_MODEL=deepseek-reasoner` 只路由 verdict）： 一场得到 **2,355 片思考分片 / 8 路 `verdict:*` 通道**，账本 `reasoningTokens` 大于 0，同一场正文分片 5,814 片，两条通道都不进事件表。一条要如实说明的代价：模型给的思考文本通常是**英文**（如 “The user asks: …”），这是模型侧行为，我们不翻译——硬翻译会让「思考」变成另一种编造。

2.8 本章要点

- 意图控制不是写提示词，是**四层可判定的机制**：声明（契约）→ 校验（锚定）→ 记账（预算）→ 收敛（规则）。
- 每条提问必须锚定简历原文，这是「提问可证伪」的地基，也是幻觉提问被物理消灭的原因。
- 追问预算由代码记账而非模型数数，因此死循环在**设计上**不成立，而不是「我们尽量避免了」。
- 判定与建议都要过代码复核：模型想判「站得住」必须拿出证据；想改简历不许引入新数字。
- 契约不落库全文，只落指纹，读侧重算对账——一份真值 + 一个指纹，胜过两份迟早不同步的副本。

第三章　架构设计

3.1 一条约束决定了整个架构：服务端不设构建步骤

赛题 25% 是「过程可复现性与演进链路」。对一份要交给评委复现的项目来说，**每一个「先做 A 才能做 B」的步骤都是一个失败点**：

常见步骤	失败方式
先装编译器 / 编译原生依赖	Windows 上 node-gyp 失败、Python 版本不对
先 build 后端再 run	忘了 build、build 产物过期、build 报 TS 错误
先装 Docker	评委机器没装或没权限
先申请 API Key	没有卡、没有额度、区域不支持
先建数据库	忘了迁移、路径没权限

本项目把上表里能消灭的全部消灭了，得到一个极短的复现路径：

```
git clone  →  npm install  →  npm run preview  →  打开浏览器  →  点两下
```

其中最关键的一条决策是 **ADR-0001：服务端不设构建步骤，直接用 Node 原生 TypeScript 运行。**

3.1.1 为什么这条能成立

Node 22.6+ 提供类型剥离（type stripping），可以直接运行 `.ts` 文件。但有一条众所周知的限制： **类型剥离默认不作用于 node_modules 内的文件。** npm workspaces 的包在 `node_modules/` 下是符号链接， 因此理论上 `import '@crossexam/shared'` 会被当作「node_modules 内的模块」而拒绝剥离。

这个假设在 P1 阶段用一条最小验证钉死了（`.tmp/node-smoke.mjs`，纯 `node` 运行）：

验证项	结果
`import '@crossexam/shared'` 拿到 46 个导出	成功
直接 import `replay.ts` / `cassette.ts`	成功
跨包调用 `buildContracts(['tech','hr'], ...)`	返回 2 条契约
`chunkText` 分片后拼接	与原文逐字相等

原因是 Node 会先 realpath：符号链接解析后文件真实位置在 `node_modules` 之外，于是类型剥离正常生效。 **这条假设不是查文档查来的，是实测出来的**——这也是本文档反复强调的方法：凡是架构依赖的前提，都要有一条可复跑的最小验证。

3.1.2 代价与边界

代价	处置
不能用 TS 的装饰器 / enum 等需要转译的语法	代码里本来也不用
类型检查与运行分离（运行时不做类型检查）	`npm run typecheck` 单独跑 `tsc --noEmit`，纳入提交门禁
生产部署不适合	本项目是本地优先的桌面级工具，不做服务端部署
前端仍需构建	前端是浏览器代码，必须 Vite 构建；但只有一条 `npm run build`

3.2 模块划分

```
D:\CZB
├── packages/
│   ├── shared/          领域模型与纯函数内核（零依赖、无 IO、100% 可单测）
│   │   ├── domain.ts        领域类型：Claim / Probe / Answer / Verdict / Suggestion
│   │   ├── anchor.ts        证据锚定：引文 → 字符区间
│   │   ├── segment.ts       简历确定性切分：小节 / 条目 / 段落
│   │   ├── budget.ts        追问预算账本（不可变）
│   │   ├── contract.ts      意图契约与确定性提示词渲染
│   │   ├── schemas.ts       模型输出的 zod 契约与解析
│   │   └── util.ts          确定性 id、稳定序列化、哈希
│   │
│   ├── server/          编排与 IO
│   │   ├── llm/             LLM 适配层：live / record / replay 三态 + 卡带 + 流式包装
│   │   ├── orchestrator/    五阶段：extract / probe / answer / verdict / suggest + run 编排
│   │   ├── store/           node:sqlite 建表、迁移与仓储
│   │   ├── http/            Hono 路由 + SSE + 静态托管
│   │   ├── pipeline.ts      编排 → 落库 → 视图 的一体化入口
│   │   ├── report.ts        Markdown 报告渲染
│   │   └── bin/serve.ts     服务入口
│   │
│   └── web/             Vite + React 19 + Tailwind v4
│       ├── api.ts           HTTP 契约与 SSE 解析
│       ├── state.ts         事件流折叠成界面状态的纯函数
│       ├── labels.ts        文案（与 shared 的漂移由测试看守）
│       └── components/      四栏界面
│
├── tools/
│   ├── dsh-export/      DSH 会话日志 → Prompt 链快照（提交物 #2 的生成器）
│   ├── smoke/           真进程冒烟（起服务、打接口、等 SSE 收尾）
│   ├── ui-shots/        无头浏览器截图器，兼作控制台报错门禁
│   ├── repro/           干净目录复现预演
│   └── docs/            Markdown → HTML → PDF 技术文档构建
│
├── fixtures/llm/        29 盘离线卡带（按提示词指纹寻址）
├── docs/                ADR / 技术文档 / 截图 / Prompt 链快照
└── data/                运行时 SQLite（已 gitignore，含用户简历隐私）
```

3.2.1 划分原则：按「依赖方向」而不是按「技术层次」

包	允许依赖	禁止依赖	理由
shared	只有 Node 标准库（`node:crypto`）	任何 IO、任何网络、任何数据库	纯函数才好测；937 行源码配 489 行测试
server	shared + Hono + zod	不依赖 web	服务端不知道前端长什么样
web	React + 自己的 api.ts	**不 import @crossexam/shared**	见 3.4

shared 里唯一的 IO 痕迹是 `util.ts` 的 `node:crypto`（算哈希），这一处恰好是 web 不能直接引 shared 的原因，也解释了为什么 web 要抄一份文案再用测试守住（3.4 节）。

3.3 LLM 适配层：一个接口，三种实现，一条卡带

3.3.1 接口

```
export type LlmMode = 'live' | 'record' | 'replay';

export interface LlmClient {
  readonly mode: LlmMode;
  complete(req: LlmRequest): Promise<LlmResult>;
  stream(req: LlmRequest): AsyncIterable<LlmStreamEvent>;
}
```

三个模式共用同一个请求结构，差别只在「结果从哪来」：

模式	结果来源	用途
live	真实 HTTP 调用	联网跑，用户填了 Key 时
record	真实 HTTP 调用 + 落盘成卡带	录制演示素材
replay	从卡带读	**默认模式**，评委零配置跑通全流程

3.3.2 卡带：用提示词指纹寻址

卡带（cassette）是一份 JSON 文件，文件名是提示词的指纹：

```
const digestFor = (req: LlmRequest) =>
  shortHash(stableStringify(shapeOf(req)), 24);

// shapeOf 只取这五项：
// { system, messages: [{role, content}], temperature, maxTokens, json }
```

刻意不包含模型名与 purpose。理由是换模型不该让整盘卡带失效——同一份提示词问出来的东西， 在演示意义上等价于同一段素材。这条决策也解释了为什么「加流式」不需要重录（channel 不在指纹里）。

回放客户端的失败方式是**响亮的**：

```
LlmError: 回放模式找不到这一条记录。用途「extract」的指纹是 b1206dc35699453a6dfbaa28，
请用 CROSSEXAM_MODE=record 联网跑一次把它录下来。
```

绝不静默降级到「跳过这一步」或「返回空结果」。这条选择在 `findings.md` F12 里有完整教训： 录制端第一版因为逐项容错，跑完 exit 0 但只写出 16/27 盘卡带，10 条回答全部缺失，stderr 干干净净。

3.3.3 记账包装：任何客户端都被套一层

```
withAccounting(inner, { db, sessionId, model })
```

它把每一次调用记进 `llm_call` 表：指纹、用途、模型、是否回放、四类 token、耗时。 界面顶部的「调用 29 次 · 回放 29 · token 23,533」就来自这里。 这层包装同时解决了两个问题：成本可见（live 模式知道花了多少）与**可复现性可见**（回放模式下「调用 N 次 / 回放 N 次」直接证明这一场没有联网）。

3.3.4 流式包装：只在需要直播时才套

```
const base = input.onStream === undefined
  ? input.client
  : withStreaming(input.client, input.onStream);
```

五个阶段的编排代码完全不知道流式的存在（它们照旧 `await client.complete()`）。 好处是：JSON 路径（`?stream=0`）与 SSE 路径共用同一份编排逻辑，两条路径都被测试覆盖，且不会出现「流式版本和普通版本行为不一致」。

3.3.5 阶段路由：换模型是装配层的事

```
withStageModels(inner, { verdict: 'deepseek-reasoner' })
```

编排层只关心「问什么」，用哪个模型是装配层的事：`withStageModels` 按 `req.purpose` 在请求上带一个 `model` 字段，五个阶段的代码一行都不用改。默认只把**判定**交给思考模型（`CROSSEXAM_REASONING_STAGES` 可改）， 理由见 ADR-0005：判定才需要「停下来想」，而追问一轮要十几次调用。 `LlmRequest.model` 与 `channel` 一样**刻意不参与卡带指纹**，所以换模型不必重录任何一盘离线卡带。

3.4 前端形态：为什么 web 不 import shared

这是一个看起来违反直觉的决策（共享类型不是好事吗？），但有一条硬理由：

shared 经 `util.ts` 依赖 `node:crypto`，把它引进浏览器包会污染打包结果。 备选方案是把 shared 拆成一个零依赖的 core 包——这在架构上更干净，但会引入一次全仓库重构， 而本项目的时间预算要留给「意图控制」与「可复现性」。因此本项目选择：**类型与文案各抄一份，用测试守住漂移。**

3.4.1 漂移怎么守

会漂移的东西	守它的测试	断言方式
五种判定的中文标签	`packages/web/test/labels.test.ts`	`toBe`（同一个对象，不是相同内容）
七种主张类别	同上	逐项对照 + 顺序不漏不重
五类人设的名字与简介	同上	逐字对照 `PERSONA_PRESETS[role].persona`
高亮区间的切分逻辑	`packages/web/test/highlight.test.ts`	9 条边界用例
事件折叠成界面状态	`packages/web/test/state.test.ts`	同一串事件喂给直播路径与历史路径，断言结果完全一致

最后一条是整个前端设计里最关键的一条：

> **直播与历史共用同一个纯函数折叠器**（ADR-0003）。

直播是把 SSE 事件一条条喂进去，历史是把库里的事件按 seq 读出来再喂进去， 两条路径的结果必须逐字段相同（除了 `phase` 由来源决定）。 这条测试保证了一个常被忽略的产品承诺：**刷新页面之后看到的，和刚才实时看到的，是同一场。**

3.4.2 界面结构：四栏 + 一条时间线

栏	内容	对应评分项
左：输入与过程	简历输入、节奏控制、意图契约、阶段时间线、实时输出、统计	意图控制（契约可摊开）
中：主张与追问	每条主张一张卡片：原文引文、追问链、作答、判定、改写建议	实用价值（结论定位到字）
右：简历原文	全文，锚点高亮，点击引文聚焦到具体字符区间	证据锚定（看得见的锚）
顶：状态条	模式、调用次数、回放次数、token、事件数、追问数	可复现性（回放可见）

3.5 存储：node:sqlite，零原生依赖

选 `node:sqlite`（Node 24 内置）而不是 better-sqlite3，理由只有一个：**不引入需要本地编译的原生依赖。** 这条约束写进了 `AGENTS.md` 第 6 节：破坏「10 分钟复现」的依赖需要 ADR 才能进。

3.5.1 三个必须知道的差异（实测，记在 findings F8）

差异	后果	处置
外键约束按连接生效	漏发 PRAGMA 会安静留下孤儿数据	`openDatabase` 里固定发 `PRAGMA foreign_keys = ON`
`prepare().all()` 返回 `unknown[]`	每处用法都要断言	仓储层用一个私有辅助函数收口（断言会绕过类型检查，收口不会）
`PRAGMA user_version` 现成可用	不需要自建版本表	迁移直接用它做版本位

3.5.2 迁移：三条教训变成三条规则

规则	来源
连接即建表（readonly 除外）	F11：同进程测试全绿，真起服务第一次写入报 `no such table: session`
迁移步骤冻结在自己时点，不引用当前 DDL	F24：v1→v2 若用当前 DDL，会一步建成 v3 表却把 user_version 写成 2
库版本比代码新时拒绝启动	防止老代码写新库，把数据写坏

当前 `SCHEMA_VERSION = 3`，表结构：

```
session(id, createdAt, updatedAt, llmMode, jobTitle, jdText, resumeText,
        resumeHash, status, budget_json, meta_json)
claim(session_id, id, ordinal, text, start, end, quote, exact, category,
      weight, status, verdict)          PRIMARY KEY (session_id, id)
probe(session_id, id, claim_id, interviewer_id, round, question, quote,
      start, end, parent_probe_id, rationale, answer_text, answer_mode,
      answer_cites_json, verdict)       PRIMARY KEY (session_id, id)
event(session_id, seq, kind, payload_json, createdAt)
llm_call(id, session_id, digest, purpose, model, replayed, usage_json, elapsedMs, createdAt)
```

复合主键（`session_id, id`）是 v2 迁移引入的。原因很具体：主张编号每场会话都从 `C1` 重新开始， 全局唯一主键会让同进程第二场会话直接撞 `UNIQUE constraint failed: claim.id`。

3.6 HTTP 层：一个端口，两种响应

接口	用途
`GET /api/health`	模式、跑法、模型、卡带目录
`GET /api/demo`	内置示例简历与 JD
`POST /api/import`	上传 PDF / Word / 文本，解析成简历正文（字节不存留；413 太大 / 415 格式不支持 / 422 解析不出文字）
`GET /api/contracts?panel=`	意图契约全文 + 指纹（纯确定性，不调模型、不读库）
`POST /api/sessions`	建档（useDemo 或 resumeText）
`POST /api/sessions/:id/run`	跑沙盘：默认 SSE 直播，`?stream=0` 走 JSON
`GET /api/sessions/:id/events?from=`	事件续传
`GET /api/sessions/:id/report.md`	下载 Markdown 报告
`GET /api/sessions/:id/report.html?print=1`	可打印 HTML 报告（`print=1` 时自动调 `window.print()`，PDF 由浏览器另存）
`GET /api/sessions/:id/report.doc`	Word 报告（同一份 HTML + `application/msword`）
`GET /api/stats?session=`	调用账本统计

3.6.1 SSE 的收尾承诺

SSE 有三个终止事件，任何一个发生都意味着这一场结束了：

事件	含义
`result`	正常跑完，附小结
`fatal`	致命失败（例如回放模式缺卡带），附原因
连接关闭	客户端断开

「一定会以成功或明确失败收尾」这条承诺由真进程冒烟守着（`tools/smoke/smoke.mjs` 会等 SSE 收尾并断言收到了 `result` 或 `fatal`）。

3.6.2 单端口托管前端

`mountWebApp(app, distDir)` 在 `/api/*` 之外挂静态托管 + SPA 回退。 这样评委只需要打开一个地址，不需要记两个端口，也不会有跨域问题。 服务入口用 `new URL('../../../web/dist', import.meta.url)` 定位前端产物，**因此从任何工作目录启动都能找到。**

3.6.3 报告导出：服务端出 HTML，PDF 交给浏览器

同一份 `SessionView` 有三种呈现：Markdown（`report.ts`，便于携带与 diff）、可打印 HTML（`report-html.ts`，便于阅读与打印）、 Word（`.doc` 后缀 + `application/msword`，便于接着改）。**服务端不生成 PDF**：那需要带一个无头浏览器或 PDF 库， 前者把「十分钟复现」变成赌评委机器上装了什么，后者违反零原生依赖。取舍详见 ADR-0006。

HTML 报告不引用任何外部资源，保存单文件即可离线打开；页脚写明「简历与报告都没有离开这台机器」。 打印脚本只在 `?print=1` 时注入——默认打开不会突然弹打印对话框（有测试守住）。

3.6.4 简历导入：解析成文本，但不留档

`POST /api/import` 只做一件事：把上传的字节变成简历正文，填进投料台的输入框，然后**字节就被丢掉**—— 不写临时文件、不入库、不进日志。于是「简历没有离开这台机器」在导入这条路径上也成立（上传的字节连磁盘都不落）。

解析按格式分三条路，每条都尽量少欠依赖：PDF 用 `unpdf`（纯 JS，零原生编译），`.docx` 自己解 zip （`node:zlib` 的 `inflateRawSync` 拆出 `word/document.xml`，不引 SDK），纯文本先按 UTF-8 解、出现替换字符再试 GBK （中文简历的现实情况）。老版 `.doc` 是二进制复合文档，明确拒绝并提示另存为 `.docx`——**宁可给一句可执行的话，也不给一段看起来像正文的乱码。** 选型对比与三个反直觉的 PDF 行为见 ADR-0007、findings F39；导入器自己有 11 条单测，HTTP 分档另有 4 条。

3.7 工程质量：门禁四道

`npm run verify` 是提交前必须全绿的一道门，它由四件事组成：

顺序	命令	证明什么	当前规模
1	`npm run typecheck`	类型对（`tsc --noEmit`，含各包）	全仓库
2	`npm run test`	逻辑对（vitest）	36 个文件 / 360 条断言 / 3.5 s
3	`npm run smoke`	**产品能跑**（真起进程、真打 HTTP、真等 SSE）	9 项
4	`npm run build`	前端能构建	vite，27 modules

第 3 道是 `findings.md` F11 的直接产物：同进程的 `app.request()` 测试全绿，真起服务却第一次写入就报没有表。 **单元测试证明的是「函数逻辑对」，冒烟证明的是「产品能跑」，这两句话之间隔着一个进程边界，而事故恰好长在边界上。**

除 verify 之外还有三个可选门禁，都做成了命令：

命令	作用	什么时候跑
`npm run shots`	无头浏览器点一遍全流程，出 14 张截图，**控制台有报错即失败**	改了界面之后
`npm run repro`	干净目录 clone → install → verify → 起服跑一场，逐步计时	改复现路径之后

命令	作用	什么时候跑
`npm run seed:demo`	重新生成 29 盘离线卡带并自检	改了提示词之后

3.7.1 代码规模与测试密度

模块	源码行	测试行	说明
packages/shared/src	937	489	纯函数，测试密度最高
packages/server/src	5823	3521	编排 + IO + 导入解析 + 报告三种形态，含脚本化模型夹具
packages/web/src	3347	979	折叠器、文案与主题变量（含 index.css）
tools/	2731	490	导出器 / 冒烟 / 截图 / 界面点测 / 复现 / 文档构建（只计 .mjs，测试目录另计）
合计	**12838**	**5479**	测试/源码 ≈ 0.43

仓库里 **0 个 TODO / FIXME / HACK、0 处** `as any`**、0 处** `@ts-ignore`（全仓库 grep 实测）。 console.log 只出现在两个 CLI 入口（serve.ts 与 seed-demo.ts）。

3.8 本章要点

- 服务端零构建是整条复现路径的地基，它成立的前提是被实测验证过的，不是查文档查来的。
- 模块按依赖方向切：shared 无 IO、server 不知前端、web 不引 shared（用测试守漂移）。
- LLM 适配层一个接口三种实现，卡带用提示词指纹寻址，缺卡带时响亮报错而不是静默降级。
- 直播与历史共用同一个折叠器，保证「刷新后看到的和刚才看到的是同一场」。
- 门禁四道，其中真进程冒烟是不可替代的那一道。

第四章　可复现性论证

赛题 25% 给「过程可复现性与演进链路」。这一章不讲愿景，只回答三个可核查的问题：

1. **别人能不能在我的机器之外跑起来？**（4.1–4.3）
2. **没有 API Key 能不能看到完整效果？**（4.4）
3. **我凭什么说这些提交是真做的，而不是最后一次性倒进去的？**（4.5–4.6）

4.1 复现路径：四条命令

```
git clone <仓库地址>
cd crossexam
npm install
npm run preview
```

然后打开 http://127.0.0.1:8787，点「一键示例」，点「开始质询」。

步骤	需要什么	不需要什么
clone	网络	不需要账号（公开仓库）
install	Node ≥ 22.6（实测 24.14.0）、npm	不需要 pnpm / yarn、不需要编译工具链
preview	磁盘可写	不需要 Docker、不需要 API Key、不需要数据库服务
浏览器操作	任意现代浏览器	不需要装任何客户端

4.1.1 实测耗时（干净目录，`npm run repro` 的输出）

步骤	耗时	说明
git clone	4.0 s	含 29 盘卡带与 14 张截图
npm install	14.4 s	116 个包，来自 npmmirror
npm run verify	13.1 s	类型检查 + 360 条断言 + 冒烟 + 构建
起服 + 跑完一场 + 下载报告	0.4 s	回放模式，21 ms 跑完整场
合计	**33.9 s**	距 10 分钟上限有 17 倍余量

这个表不是估的，是 `tools/repro/repro-check.mjs` 在一个**全新临时目录里 git clone 出来**的仓库上逐步计时得到的。 同一台机器多次预演落在 34–40 秒之间（`clone` 受磁盘缓存冷热影响最大），这张表记的是最近一次完整预演。 写文档时的第一条原则是：**复现耗时必须是实测数据，且必须由命令生成，不能手写**（决策 D16）。

4.2 为什么没有原生依赖

依赖	选择	如果换成常见的替代品会怎样
数据库	`node:sqlite`（Node 内置）	better-sqlite3 需要 node-gyp + Python + VS Build Tools，Windows 上失败率极高
服务端框架	Hono（纯 JS，零依赖链）	Express 也行，但 Hono 自带 `streamSSE` 且体积小
校验	zod（纯 JS）	—
.env 载入	`process.loadEnvFile`（Node ≥ 20.12 内置）	dotenv 会多一个包，且本项目只需要一行
浏览器驱动	系统 Edge/Chrome + CDP + Node 全局 WebSocket	Playwright 会下载 200 MB 浏览器

依赖	选择	如果换成常见的替代品会怎样
文档渲染	自写 md2html（零依赖）	pandoc 需要单独安装
截图	CDP `Page.captureScreenshot`	—

上表每一行都能对应到 `AGENTS.md` 第 6 节那条约束：「引入需要本地编译的原生依赖会毁掉 10 分钟复现，需要 ADR 才能破例」。 至今没有破例。

4.3 三个「静默失败」的坑，以及它们如何变成规则

可复现性的敌人往往不是「跑不起来」，而是「**看起来跑起来了，其实用的是别的东西**」。本项目踩过三个：

坑	现象	变成的规则
说明书写了 `cp .env.example .env`，程序从没读过它	填了 `CROSSEXAM_MODE=live` 仍是回放，配置静默失效	启动横幅必须打印「已载入哪个 .env」或「没有 .env」
端口上挂着旧进程	live 实测报「0 分片」，其实测的是流式功能落地**之前**的旧服务	一次性实测起服务前必须自检端口为空，并核对写入的是自己的临时库
通用 .gitignore 模板的 `bin/` 段	源码被静默忽略，P0 提交漏掉了导出器 CLI	忽略规则要**正反各测一遍**：密钥被挡住 + 源码没被挡住

第二、三条的完整复盘在 `findings.md` F22 与 F6/F10。它们共享同一个教训：

> **退出码为 0 不代表事情办成了。凡是「静默忽略」的机制，都要在事后做一次正面确认。**

4.4 离线回放：没有 Key 也能看到完整效果

4.4.1 卡带机制

回放模式下，每一次模型调用的「问题」被哈希成一个 24 位指纹，**答案**就存在以该指纹命名的 JSON 文件里：

```
fixtures/llm/
├── 0a3f...c2.json    extract 阶段的回答
├── 1b7e...d9.json    probe 阶段某位面试官的回答
└── ...               共 29 盘
```

指纹只对请求的五项内容做哈希（system / messages / temperature / maxTokens / json）， 因此**改了提示词，指纹就变，旧卡带自然失效并响亮报错。**这既是一个约束，也是一道门禁（4.4.3）。

4.4.2 29 盘卡带覆盖了什么

阶段	卡带数	说明
extract	1	抽主张
probe	9	3 位面试官 × 3 轮
answer	10	10 条追问各一次作答
verdict	5	5 条主张各一次判定
suggest	4	4 条需要改写的建议（「站得住」的那条跳过）

跑完一场离线演示的权威数字（`.tmp/doc-stats.mts` 直接调 `runAndPersist` 实测）：

指标	值
耗时	21 ms
轮数 / 主张 / 追问 / 判定 / 建议	3 / 5 / 10 / 5 / 4

指标	值
被锚定机制拦下的主张	1
判定分布	站得住 1 · 表述过度 1 · 证据缺失 2 · 无法回答 1
token	输入 21,266 · 输出 2,267
每位面试官追问数	tech 4 · hr 3 · hiring_manager 3

4.4.3 卡带是合成的，而且必须被证明是合成的

这 29 盘卡带由 `createDemoScriptedClient` 用**确定性脚本**生成，不是真实模型的输出。这一点在文档里、在 `fixtures/README.md` 里都写明，并且有三重可核查的痕迹：

痕迹	怎么核查
每盘卡带的 `model` 字段都是 `scripted-demo`	打开任意一个 JSON 就能看到
`recordedAt` 是固定常量 `2026-10-26T00:00:00.000Z`	因此重跑 `npm run seed:demo` **逐字节相同**，git status 干净
usage 是按字符数折半的估算值，不是计费数据	生成器里有明确注释

为什么必须这么做？因为**卡带是要提交进公开仓库的**。真实模型输出 + 真实简历 = 隐私泄漏。 因此 `fixtures/README.md` 里写了一条红线：只允许用示例简历录制卡带。

4.4.4 提示词漂移门禁

卡带最大的风险是「代码改了提示词，卡带没重录，演示静默变味」。守住它的是一条测试：

```
packages/server/test/demo-cassette.test.ts
  用仓库里已提交的 fixtures/llm 起一个真实 app，
  POST /api/sessions（useDemo）→ POST /run?stream=0
  断言：200 / 主张 5 / 被拦 1 / 判定含 unanswerable 与 solid / 建议 ≥ 1
```

这条测试跑的是**已提交的素材**，因此任何人改了提示词而忘了 `npm run seed:demo`，提交门禁立刻变红。 它同时也是一份「离线演示确实能跑完」的回归证据。

4.4.5 想联网跑真模型怎么办

```
cp .env.example .env       # 填 LLM_BASE_URL / LLM_API_KEY / LLM_MODEL
# .env 里设 CROSSEXAM_MODE=live
npm run start
```

服务启动横幅会明确打印当前模式与「是否已载入 .env」。实测在 DeepSeek 上跑通（见 5.5 节）。

4.5 演进链路：120 余次提交是怎么来的

4.5.1 规则写在仓库里

`AGENTS.md` 第 2 节把赛题的提交要求变成了可执行的工程规则：

规则	内容
粒度	一个提交 = 一个可独立说明的改动。禁止 `git add -A && git commit` 式大杂烩
判据	提交前先问：**这个提交对应哪一次 AI 对话？** 答不上来就说明粒度不对
格式	Conventional Commits + 中文简述（不超过 50 字）+ 正文写「为什么这么改」
署名	**禁止** `Co-Authored-By` 等 AI 署名尾注（GitHub 会把它们解析成账号并计入贡献者列表）

4.5.2 阶段与提交的对应

阶段	内容	提交数（约）
P0	仓库初始化、工程约定、DSH 会话导出器	5
P1	领域内核：锚定 / 切分 / 预算 / 契约 / schema；LLM 适配层	17
P2	五阶段编排、存储、HTTP/SSE、报告、示例简历、冒烟	15
P3	前端：包骨架、HTTP 契约、事件折叠、三栏界面、单端口托管	7
P4	截图器、意图契约可见、复现预演、README 复现指南、流式吐字	30+
P5	技术文档、Prompt 链刷新、发布清单	进行中

4.5.3 一个具体例子：一次 Bug 修复对应哪一次对话

以「修改建议全部失败」这个 bug 为例，它对应的提交链是：

```
c8a6e90 fix(shared): 修改建议不再要求模型自报主张编号
```

提交正文写的是「为什么」：提示词从未要求模型输出 claimId，而 schema 把它列为必填； 合成卡带恰好写了这个字段，于是离线全绿、真实模型全红。这类信息只有写进提交正文才留得下来。

4.6 Prompt 链：过程证据不是事后补写的

赛题要求提交「≥3 个核心功能迭代的完整 Prompt 链（提问、AI 建议、如何引导修 Bug）」。

本项目的做法是**从第一行代码起自动导出**：

环节	实现
原始数据	DSH 把每一次会话写成 zstd 多帧压缩的 JSONL，落在 `%APPDATA%\dsh-desktop\harness\sessions\<工作区>\<会话>\session.v4.jsonl.zstd`
解析	`tools/dsh-export` 逐帧解压（`zstdDecompressSync` 只解第一帧，必须扫描魔数 `28 B5 2F FD`），按 turn 组织成时间线
脱敏	自动识别 6 类密钥格式（OpenAI / Anthropic / GitHub / AWS / Bearer / KEY=value 赋值），命中即替换
过滤	只把 `source.kind === 'user'` 的消息当真人提问，系统注入（runtime-context / skill-catalog / plugin:hindsight / time-context / agent-instructions）全部丢弃
分页	超过 40 万字符自动按**条目**边界切分（不是按轮次，因为单轮可能 144 万字符），每份都能在网页上直接渲染
产物	`docs/prompt-chain/` 下 11 份分片，共约 4.9 MB，覆盖整个开发过程

这条链带来三个别的方式给不了的性质：

性质	含义
不可事后美化	快照是会话日志的直接产物，改一个字就会和日志对不上
包含失败	走错的路、被推翻的方案、修 bug 的过程都在里面，不是只挑成功的展示
可复跑	`npm run export:prompt` 一条命令重新生成，不需要手工整理

4.7 本章要点

- 复现路径四条命令，33.9 秒（实测，由 `npm run repro` 生成），17 倍余量。
- 零原生依赖是硬约束，至今没有破例。
- 离线回放让「没有 Key 也能看到完整效果」成立，29 盘合成卡带 + 一条漂移门禁守着它。
- 提交粒度规则写在仓库里，120 余次提交每一次都能对应到一次具体的开发动作。
- Prompt 链是会话日志的直接产物，自动导出、自动脱敏、自动分页——过程证据不是作文。

第五章　实测证据

这一章只放**可复跑的数字**。每条结论后面都标了它是怎么测出来的；凡是无法复跑的观察（例如「真实模型偏保守」），都会明确写成观察而不是结论。

5.1 门禁现状

```
npm run verify
  1/4 typecheck   tsc --noEmit（根 + shared + server + web）
  2/4 test        36 个测试文件 / 360 条断言 / 3.5 s
  3/4 smoke       9 项真进程冒烟
  4/4 build       vite 8.3.5 / 27 modules / CSS 24.67 kB / JS 275.79 kB（gzip 86.62 kB）
  exit 0
```

测试分布：

包	测试文件	覆盖重点
shared	5	锚定的四种拒绝、归一化映射、预算五道闸门、契约渲染确定性、schema 解析
server	17	五阶段编排、闸门顺序、SSE 收尾、迁移、卡带、流式、阶段路由、报告、简历导入（PDF / docx / 文本共 11 条）
web	8	文案漂移与判定口径、高亮切分、事件折叠（直播 vs 历史）、流式分片解析、报告网址、配色主题、新手教程文案
tools	6	分页、zstd 多帧、脱敏、Markdown 渲染

5.2 三条最有说服力的测试

5.2.1 直播与历史必须给出同一个界面

`packages/web/test/state.test.ts` 把同一串 15 个事件喂给两条路径：

```
路径 A：sandboxReducer + {type:'event'}        （模拟 SSE 直播）
路径 B：stateFromHistory(events)               （模拟刷新后从库里读）
断言：claims / probes / budget / errors / interviewers / rejectedClaims / eventCount 完全一致
      只有 phase 不同（'running' vs 'done'）
```

这条测试守的是产品承诺「刷新后看到的和刚才实时看到的是同一场」。它一共有 17 条断言，其中还覆盖了：预算事件让主张关停、作答报错在卡片上显示、空追问轮自己补提示、未知 claimId 与重复 probeId 被丢弃、致命错误把 phase 置为 failed。

5.2.2 提示词必须是确定性的

`packages/server/test/orchestrator-extract.test.ts` 有一条：

```
同一个输入渲染两次提示词 → 逐字节相同
```

理由不是洁癖：卡带按**提示词指纹**寻址，提示词抖一字节，整盘离线回放就失效。因此五个阶段的提示词全部是纯函数，不含时间戳、不含随机数、不依赖 `Object.keys` 的顺序。

5.2.3 锚定不采信模型给的坐标

同文件另一条：给模型一个**错误的 start/end**，但引文是对的，断言最终锚点是程序用 `indexOf` 重新定位出来的区间。这条把「证据锚定」从一句口号变成了可验证的行为。

5.3 全接口验收：78 项

`.tmp/api-matrix.mjs`（一次性验收脚本，自起服务、自建临时库）覆盖：

类别	项数	例子
健康 / 示例 / 契约	12	契约指纹格式、`?panel=tech,cto` 返回 400 并列出可选值
建档错误分支	4	简历太短（少于 30 字）返回 400 且中文提示
完整跑一场	18	轮数 3、主张 5、追问 10、判定 5、建议 4、被拦 1、usage 输出 2,267
落库校验	9	事件 18 条且 seq 连续、`?from=10` 续传 8 条、账本 calls=29
报告	6	四个章节齐全、Markdown 可直接下载
SSE	5	含 `stream` 分片且**分片不进事件表**
静态托管	4	首页 200、SPA 深路径回退、未知接口中文 404

结果：**78 PASS / 0 FAIL。**

5.4 真浏览器实测：控制台 0 报错

不装 Playwright，用系统 Edge + CDP + Node 自带 WebSocket 驱动（`tools/ui-shots/shots.mjs`）：

项	结果
截图	14 张，全部由命令生成（含新手教程与浅色配色两张）
控制台	**0 条报错 / 0 条警告**（收 Runtime.exceptionThrown、consoleAPICalled 的 error 与 warning、Log.entryAdded）
流程	点「慢放」→「一键示例」→「开始质询」，跑到判定与建议全部出现
界面数字	调用 29 次 · 回放 29 · token 24,105 · 事件 18 · 追问 10
与后端一致性	界面判定条数与服务端 `verdicts` 条数一致

截图清单（`docs/screenshots/`）：

图	内容
01-intake.png	空状态：四条机制逐条说明 + 意图契约三条 pending
02-demo-loaded.png	载入示例简历
03-running.png	直播中：三位面试官同时追问
04-live-output.png	**实时输出栏：模型正在写的人话**（原始输出是 JSON，界面已还原）
05-thinking.png	**同一栏的「思考 + 输出」两行**：斜体是思考分片，正下方是正文分片
06-done-top.png	跑完总览
07-verdicts.png	判定卡片，含「这条判定不是模型直接给的」
08-resume-focus.png	点引文后右栏聚焦到「第 81–108 字」
09-history.png	刷新后从历史恢复
10-contracts.png	意图契约摊开 + 徽章「与运行时一致 · 指纹 b2171c82」
11-system-prompt.png	该面试官实际拿到的 System Prompt 原文
12-help.png	第一次打开自动弹出的新手教程：四步上手、三种模式对照表、隐私口径
13-light.png	**浅色配色**：白天/投影仪/打印稿上看得清；判定卡片里带「为什么这样判」与「判据展开」
14-report.png	**服务端渲染的可打印报告**：元信息表、过程说明、带判定配色的主张与判定——PDF 就是它经浏览器打印得到的

5.5 真实模型实测（DeepSeek，live 模式）

这一节的意义是：**证明离线演示不是靠卡带撑起来的空壳**，接上真模型确实能跑。

5.5.1 端到端结果

项	值
模型	deepseek-chat（OpenAI 兼容协议）
一场耗时	20.0 s
主张 / 追问 / 轮数 / 建议	10 / 18 / 3 / 9
token	输入 47,941 · 输出 8,355 · 缓存命中 7,424
判定	10 条「证据缺失」（判定口径调整后的实测，见 5.6 第 5 条）
被锚定机制拦下的主张	0（真实模型的引文质量比预期好）

5.5.2 真实追问的质量抽样

下面这条是真实模型对「首屏加载从 2.4s 降到 0.8s」的追问，未经任何修改：

> 2.4s 和 0.8s 这两个首屏加载数字是怎么测出来的——用什么工具、在什么网络条件和设备上、取的是几次采样的什么统计口径?

求职者 Agent 的回答（同样未经修改）：

> 这个……简历里只写了「首屏加载从 2.4s 降到 0.8s」这个结果，具体用什么工具测的、什么网络条件和设备、采样几次取什么统计口径，简历里没有写，我这边没法给你具体细节。

这一问一答就是整个产品的价值主张：它不是「AI 帮你写简历」，而是「AI 找出你答不上来的那句」。

5.5.3 真实模型的流式分片

live 模式下的一场实测：**5,814 个分片 / 29 路 channel / 0 片进入事件表 / 21 条阶段事件**。接上思考模型（`CROSSEXAM_REASONING_MODEL=deepseek-reasoner`，只路由 verdict）之后再测一场：**2,355 片思考分片 / 8 路 `verdict:*` 通道 / 账本 `reasoningTokens` > 0 / 整场 22.7 s**—— 思考与正文分走两个 `kind`，但同样不进事件表。这组数字同时证明了三件事：流式真的在流、分片确实被隔离在事件日志之外、阶段事件的规模稳定在二十条左右。

5.5.4 两条诚实的观察（不是结论）

观察	说明
真实模型抽的主张比合成脚本多	361 字简历抽 8–10 条，合成脚本固定 5 条；真实模型还会把「2023.06 - 2025.03」这类时间线也抽成主张
判定口径调完之后，「无法回答」几乎不再出现	求职者 Agent 只依据简历作答，它天然说不出「我不会」，所以「无法回答」本就该是少数；数字类主张更容易落在「证据缺失」（简历没写口径，改简历即可）。代价是区分度下降：这一场 10 条判定全是「证据缺失」

5.6 五个在实测中抓到的真 Bug

下面五个 bug 都不是设计阶段发现的，是**真跑起来才暴露**的。它们比任何架构图都更能说明这套工程是真的在运转。

序号	现象	根因	为什么之前没抓到
1	真实模型下 9 条修改建议全部失败	schema 要求 `claimId` 必填，提示词从未要求输出它	合成卡带恰好写了这个字段，把矛盾完整掩盖
2	同进程第二场会话 500	claim 表全局主键，而主张编号每场从 C1 重新开始	每个测试都只跑一场

序号	现象	根因	为什么之前没抓到
3	真起服务第一次写入报 `no such table: session`	建表靠调用方显式调 migrate，测试都调了、真进程没调	同进程 `app.request()` 测试不经过启动路径
4	live 实测「0 分片」	端口上挂着**流式功能落地之前**的旧进程	没有验证「测的是谁的进程」
5	判定徽章与模型写的理由互相矛盾	代码级收敛把「全体未答」一律改判「无法回答」，吃掉了模型判的「证据缺失」	合成卡带的作答脚本恰好都答得上，离线演示永远不触发这条规则

每一个都变成了规则或门禁：

Bug	变成的规则
1	给模型输出造夹具时，唯一真相是**提示词里的输出要求**，不是 zod schema（F23）
2	复合主键 + 迁移冻结在自己时点（F24）
3	`openDatabase` 连接即建表；门禁加入真进程冒烟（F11）
4	一次性实测起服务前必须自检端口为空、核对写入的是自己的库（F22）
5	代码级收敛只做「防过于乐观」，责任归属交回模型；两档判据写成可判别的「责任在谁」（F31）

5.7 本章要点

- 门禁四道：类型、逻辑、**产品能跑**、能构建。第三道不可替代。
- 全接口 78 项验收全绿；界面点测 40 项全绿；真浏览器 14 张截图、控制台 0 报错；

报告三种形态另有真机验收（`.tmp/report-check.mjs`，12/12）：HTML 经 Edge 打印得到 438305 B / 6 页 PDF，界面三个按钮分别指向 `.md` / `.html?print=1` / `.doc`。

- 真模型跑得通：20 s、10 条主张、18 次追问，追问质量可直接引用于演示视频。
- 五个真 bug 都变成了规则，而不是被悄悄修掉——这才是「演进链路」的实质。

第六章　局限、取舍与后续工作

一份技术文档如果只讲做成了什么，它的可信度反而更低。这一章写清楚：**什么没做、为什么没做、如果继续做会先做哪一件。**

6.1 已知局限

#	局限	影响	现状
1	求职者 Agent 只依据简历作答，不使用用户的真实记忆	它答不上来的问题，用户本人**可能**答得上来	这是刻意的：产品测的是「简历这句话本身能不能自证」，不是「你本人会不会」。报告里也如实写明这一点
2	判定区分度不足：真实模型下几乎全判「证据缺失」	用户看不到「表述过度 / 与原文矛盾 / 无法回答」这些信息量更大的档位	口径已从「全体未答一律改判」修正为「责任在谁」（见 2.6.1），但求职者 Agent 只依据简历作答，天然说不出「我不会」，所以「无法回答」稀少是结构性的
3	追问策略依赖单一模型的角色扮演	三位面试官的提问风格差异不如真人明显	契约层已把差异结构化（tactics / forbidden 各不相同），但同一模型扮演多个角色仍有同质化倾向
4	只支持中文简历	英文简历的锚定与切分未验证	锚定逻辑本身与语言无关，但 segment 的小节识别按中文标题写死
5	不做简历解析（PDF / DOCX）	用户需要粘贴纯文本	有意为之：解析 PDF 会引入原生依赖与大量边界情况，与「10 分钟复现」冲突
6	单机单用户，无鉴权	不能直接部署到公网	产品定位是本地优先工具，简历属隐私数据，**不上传任何第三方存储**

6.2 三个明确的取舍

6.2.1 抄一份文案，而不是拆包

web 不 import shared（因为 shared 经 util.ts 依赖 `node:crypto`），代价是判定标签与人设文案要抄一份。 正确的做法是把 shared 拆成零依赖 core + 带 IO 的 adapter，但那是一次全仓库重构。 本项目用**漂移测试**（`toBe` 断言同一个对象）替代重构，把风险压到「测试红了才发现」，而不是「重构期间功能停摆」。

6.2.2 合成卡带，而不是录真实模型输出

真实模型输出 + 真实简历 = 隐私泄漏，而卡带要提交进公开仓库。因此演示卡带是确定性脚本生成的， 并用三重痕迹标明它是合成的（model 字段、固定 recordedAt、估算 usage）。 代价是离线演示的追问质量不如真实模型（合成脚本只有 5 条主张，真实模型抽 8–10 条）， 补偿手段是把真实实测的数字与追问原文写进本文档 5.5 节，让两者都能被核查。

6.2.3 分片不落库

流式分片走 SSE 但不进事件表，代价是刷新页面后看不到「刚才正在写的字」。 换来的是：回放不被几万条分片拖慢、日志不吵、且「能断线续传的只有阶段事件」这条边界非常清楚。 这条取舍记在 ADR-0004。

6.3 如果继续做，先做这五件

优先级	事项	为什么是它
1	让候选人 Agent 能说「我不会」，而不只是「简历里没写」	根治 6.1 第 2 条的判定区分度问题：现在它只能引用简历，所以「无法回答」结构性稀少
2	追问阶段引入「用户补充事实」入口	用户被问住时能补一句真实情况，再判一次；这会把产品从「体检」变成「训练」
3	报告增加「按主张类别统计」	让用户看出自己是「数字类主张弱」还是「归属类主张弱」
4	支持英文简历	锚定逻辑已与语言无关，只需放宽 segment 的小节识别
5	把 shared 拆成 core + adapter	消除抄文案的技术债

6.4 结语

这个项目想做的一件事，用一句话说就是：

> **在简历投出去之前，先让三位不同的面试官把它拆一遍，并且告诉你哪一句你答不上来。**

技术上它试了三件不太常见的事：

1. **把「提问必须有证据」做成程序闸门**，而不是提示词里的请求——这让幻觉式提问在物理上无法进入系统；
2. **把「追问次数」做成不可变账本**，而不是模型自己数数——这让死循环在设计上不成立；
3. **把「过程证据」做成会话日志的自动产物**，而不是事后整理的文档——这让 120 余次提交、9 份 Prompt 链快照与本文档里每一个数字都可追溯。

第三件事也是这个项目对赛题「过程可复现性」这条 25% 权重最直接的回答： 过程不是我事后描述的，是仓库里一条命令就能重新导出的。

附：本文档自身的可复现性

本文档由 `npm run docs:pdf` 从 `docs/tech/*.md` 生成： 零依赖 Markdown 渲染（`tools/docs/md2html.mjs`）→ 无头 Edge 打印（`tools/docs/build-doc.mjs`）→ PDF。 构建时会统计页数，超过 30 页直接失败（赛题上限）。