CrossExam 质询室

> 全国高校 Vibe Coding 开发挑战赛 · AI 创新应用挑战赛（赛道 10039） 技术文档 —— 意图控制策略 / 架构设计 / 可复现性论证

多 Agent 对抗式面试沙盘：把简历里那句你其实答不上来的话，在投出去之前找出来。

项	内容
作品名称	CrossExam（质询室）
仓库	见 README 顶部（公开仓库，细粒度提交，共 120 余次）
技术栈	Node 24 + TypeScript（服务端零构建）· Hono + SSE · node:sqlite · Vite + React 19 + Tailwind v4
交付日期	2026-11-18（省赛作品提交截止）
文档版本	1.0 · 2026-10-26
演示前提	不需要 API Key、不需要数据库、不需要 Docker，一条命令起完整产品

本文档怎么读

这份文档不是功能说明书，它只回答评委评分表上的三个问题：

评分维度	权重	对应章节
过程可复现性与演进链路	25%	第四章（可复现性论证）、第五章（实测证据）
方法创新性与意图控制	20%	第二章（意图控制策略）
工程质量与架构设计	15%	第三章（架构设计）
解题有效性与实用价值	25%	第一章（问题定义）与第五章（真实模型实测）
用户体验与产品精细度	15%	3.8 节（前端形态）与第五章（真浏览器实测）

三条阅读路径，按可用时间自选：

1. **只有 5 分钟**：读第一章的 1.3 与 1.4，再看第二章的 2.2 那张四层表。
2. **想验收**：直接跳第五章，那里全是可复跑的命令与实测数字。
3. **想审设计**：第二章讲「怎么让模型听话」，第三章讲「为什么这么切模块」，第四章讲「凭什么说它可复现」。

文中所有数字都来自本机实测或仓库内的可复跑命令，来源标在数字旁边； 没有实测支撑的判断会明确写成判断，而不是伪装成结论。

第一章　问题定义：简历里那句话，你答不上来

1.1 一个具体的失败场景

求职者张明（本文档全程使用的示例人物）简历上写着两句话：

> 主导重构订单系统，首屏加载从 2.4s 降到 0.8s。 主导引入 Redis 缓存，QPS 从 800 提升到 5000。

他投出去，进了面试。面试官问：「2.4s 到 0.8s，怎么测的？取的均值还是 P75？样本量多少？」

张明答不上来。他确实做过这个优化，但那个数字是同事报给他的；他没测过，也不记得口径。 于是面试官得到两个结论：这个人对数字不负责；这份简历不可信。

问题不在于他会不会写代码，而在于简历上的每一个数字，都是一个等待被追问的主张，而他没在被追问之前演练过。

这个场景有三个关键性质，直接决定了产品形态：

性质	含义	对产品的约束
主张是可枚举的	一份简历能抽出 5–12 条「可被追问的主张」	不需要做通用对话，做「逐条质询」就够
追问是有方向的	面试官不会随机问，他们拆口径、拆归属、拆因果	追问策略可以被写成可复用的意图契约
反馈必须可执行	「你答得不好」没有价值，有价值的是「这句话改成什么」	输出必须回落到简历原文的具体片段

1.2 现有方案为什么不够

市面上的简历工具分三类，各自缺一块：

类型	代表	它能做什么	它不能做什么
简历生成 / 美化	各类在线简历编辑器	排版、模板、导出	不检验内容是否站得住
AI 润色	通用大模型对话	把句子写得更好看	会替你编，且编得比原文更自信
模拟面试	题库式 / 通用 AI 面试官	出题、打分、给建议	不锚定你的简历原文，问题与你写的东西无关

第三类是最近的形态，也是本项目的近邻。核心缺陷一句话：**它的提问不携带证据。** 「谈谈你最有挑战的项目」对任何人成立，因此对任何人都不成立——它指不出你简历里哪一句站不住。

1.3 CrossExam 的解法：把「面试」变成「逐条主张的证据审计」

CrossExam 的输入是**一份简历 + 一份目标岗位 JD**，输出是**每条主张的判定 + 回落到原文的修改建议。** 中间的过程是 3–5 位人设不同的 AI 面试官，对每条主张并发追问。

一场完整的质询有五个核心阶段，全部由程序编排、全部可回放；手里有岗位 JD 时前面会多三次读 JD 的调用， 收尾还会多一次「轮到你了」把材料反着用一遍（合计九个阶段、九种调用）：

```
简历 + JD
   │
   ├─ ⓪ 读岗位要求  jd-extract / jd-merge / jd-match
   │                          1–8 份 JD → 一张要求清单 → 与主张逐条对照（答得上 / 答得含糊 / 简历里没写）
   │                          逐份抽要求、归并、对照各一次调用；没上传 JD 就整段跳过
   │
   ├─ ① 抽取主张   extract    从简历里抽出可被追问的主张，每条必须携带逐字引文
   │                          锚不到原文的主张当场丢弃（不是降级，是丢弃）
   │
   ├─ ② 并发追问   probe      3 位面试官按各自的意图契约同时提问
   │                          每轮：预算闸门 → 锚定闸门 → 去重闸门
   │
   ├─ ③ 求职者作答 answer     求职者 Agent 只能引用简历原文作答，编造的引文被丢弃
   │                          连续答不上来 → 该主张自动关停（不再浪费追问）
   │
   ├─ ④ 判定       verdict    每条主张给出：站得住 / 表述过度 / 证据缺失 / 与原文矛盾 / 无法回答
   │                          两条代码级收敛：全没答上来又判站得住 → 证据缺失；要证据却拿不出 → 证据缺失
   │
   ├─ ⑤ 改写建议   suggest    把「答不上来」翻译成「这句话该怎么改」
   │                          四道闸门：改前原文必须定位得到、不许引入新数字、不许等于原文
   │
   └─ ⑥ 轮到你了   counter    给用户几句可以反问 HR 的话
                              每句必须锚回简历原话或 JD 原文，锚不回当场丢弃；回答由沙盘代答并注明「模拟」
```

五种判定不是设计出来的修辞，而是**证据审计的五个可能结论**：

判定	含义	触发条件（产品语义）
站得住	主张有原文支撑，且追问下给出了可核验的口径	答得上 + 能援引原文
表述过度	主张本身没错，但说法超出了证据能支撑的范围	答得上但暴露了口径不一致
证据缺失	主张可能成立，但拿不出任何可定位到简历的证据	模型判定（责任在简历写法）；或模型判 solid/contradicts 却给不出引文 → 代码降级
与原文矛盾	追问下的回答与简历原文冲突	回答援引的原文与主张指向的事实相反
无法回答	候选人被追问后明确表示拿不出、不记得、没做过	模型判定（责任在人，风险最高的一类）

1.4 与近邻产品的差异（不是形态差异，是判断依据的差异）

赛题禁止「用已有开源项目包装参赛」，所以这里做的是**能力对照**而非功能对照。立项时研究过一个同类产品 （本地优先的 AI 求职工作台，Apache-2.0，545 次提交），它把「防编造」做在**生成侧**：维护一份用户核实过的事实台账，只有核实过的才允许进入生成。

维度	事实台账式（生成侧防编造）	CrossExam（质询侧做压力测试）
触发时机	写简历之前	简历写完之后、投出去之前
核心动作	拦截：不许写没核实过的事实	质询：写下的话经不经得起追问
输出物	一份更安全的简历	一份带判定与改写建议的审计报告
对模型的要求	不许发挥	必须发挥（扮演不同面试官施压）
失败模式	台账太严，简历写不出来	追问太空，等于没问

两者互补而非重叠：台账保证「写下来的都是真的」，质询保证「写下来的都答得上」。选后者的理由是它多一个性质： **追问可以被证伪**——一次提问如果锚不到简历原文，它就是一条可被程序判定为无效的提问。这是第二章全部控制手段的起点。

1.5 谁会用、用在什么时候

用户	场景	得到的价值
应届生 / 转行者	简历投出去石沉大海，不知道问题在哪	在投递前发现「这句我答不上来」
有经验但久未面试的人	项目是两年前做的，细节忘了	被追问后知道该补哪段记忆、该改哪句话
简历辅导 / 就业指导老师	批量看学生简历	一份可下载的审计报告，指出具体句子
面试教练 / 训练营	做模拟面试	用不同人设反复施压，且过程可复现

它不是「AI 帮你写简历」，而是「AI 帮你找出简历里最脆的那一句」。这带来一个直接约束：**报告必须定位到字。** 「描述不够具体」是无效反馈；「第 81–108 字这句『首屏加载从 2.4s 降到 0.8s』答不出测量口径」才是有效反馈。

1.6 本章要点

- 问题是「简历上的数字经不经得起追问」，不是「简历写得好不好看」。
- 因此产品形态是逐条主张的质询，不是通用对话。
- 因此每条提问必须携带简历原文锚点——这是可证伪性的来源。
- 因此输出必须回落到原文的具体片段——这是实用价值的来源。

第二章　意图控制策略

赛题把 20% 的权重给了「方法创新性与意图控制」。这一章要回答的问题很具体：

> 当你有 3 个 Agent 在同一个沙盘里各自发挥时，**你凭什么说它们在你的意图之内行事?**

2.1 「在提示词里写要求」不是意图控制

大多数多 Agent 产品的控制手段是：在 System Prompt 里写一段要求，然后相信模型会遵守。 例如「每条提问最多追问 3 次」「你的提问必须来自简历原文」。

这在工程上是不成立的，理由是**提示词是建议，不是约束**：

你写的	模型实际可能做的	后果
「最多追问 3 次」	第 4 次继续问	死循环，烧钱，演示卡死
「提问要来自简历原文」	编一段听起来像简历的话	幻觉式提问，用户被问懵
「一次只问一个问题」	问三个连在一起	用户不知道答哪个
「答不上来就停止追问」	继续换角度施压	用户被反复羞辱同一件事

更麻烦的是：**这些违规不会报错。**模型会返回格式完全合法的 JSON， 里面装着一条越界的提问；如果你只校验 JSON 结构，它会一路通过，直到用户看见。

所以 CrossExam 的设计原则是：

> **凡是可以被程序判定的约束，就不要交给模型自觉。** 模型负责「想出好问题」，程序负责「保证这个问题合规」。

2.2 四层意图控制：从声明到收敛

本项目把意图控制拆成四层，每层有明确的职责边界与失败表现。

层	名字	做什么	在哪实现	被拦下时用户看到什么
L1 声明	意图契约 Intent Contract	每个 Agent 的 System Prompt 是结构化 JSON，可解释、可版本化、可 diff	`packages/shared/src/contract.ts`	界面上可展开查看契约全文与指纹
L2 校验	结构 + 锚定	模型输出必须过 zod schema；每条提问的引文必须能在简历里逐字定位	`packages/shared/src/schemas.ts`、anchor.ts	被拦下的提问列在「被拦下的追问」里，附原因
L3 记账	追问预算 Probe Budget	追问次数由代码记账，不是由模型数数	`packages/shared/src/budget.ts`	主张卡片上出现「已关停」与关停理由

层	名字	做什么	在哪实现	被拦下时用户看到什么
L4 收敛	判定与建议的代码级收敛	模型给的判定与建议还要过一遍确定性规则	`packages/server/src/orchestrator/verdict.ts`、suggest.ts	判定卡片上标注「这条判定不是模型直接给的」

这四层的顺序很重要：**先声明，再校验，再记账，最后收敛。** 每一层都只依赖上一层已经确定的产物，因此整条链路是确定性的、可单测的、可在离线模式下复现的。

2.3 L1 声明层：意图契约是数据，不是文案

2.3.1 结构

每个面试官 Agent 的行为由一个结构化对象完全决定，而不是一段散文式提示词：

```
{
  "id": "tech",
  "version": 1,
  "persona": {
    "name": "技术面试官",
    "role": "tech",
    "seniority": "senior",
    "tone": "skeptical",
    "blurb": "资深工程师，冷静、只问细节"
  },
  "goal": "验证简历里的技术栈与项目描述是否真的出自本人之手，还是只写过 demo。",
  "tactics": [
    "追问技术选型的原因，而不是「用了什么」",
    "追问具体的失败与返工",
    "把简历里的一个数字拆开问口径"
  ],
  "constraints": [
    "每次提问必须携带能从简历里逐字找到的 quote",
    "引文至少 4 个字符",
    "一次只问一个问题",
    "只问简历里写过的东西，不要新造主张"
  ],
  "forbidden": [ ... ],
  "budget": {
    "maxRoundsPerClaim": 3,
    "maxProbesPerInterviewerPerClaim": 2,
    "maxTotalProbes": 60
  }
}
```

（以上为真实数据，来自 `PERSONA_PRESETS` 经 `buildContracts(['tech'], ...)` 生成， 技术面试官契约的指纹是 `042b385f925cf50f`，HR 是 `2375be34602e49f3`，业务主管是 `b2ed25a1d9d3995a`。）

2.3.2 为什么必须结构化

好处	具体表现
可解释	界面能把「它被允许做什么、被禁止做什么」摊开给人看，不用猜
可版本化	`version` 字段 + 内容指纹，改一个字指纹就变
可 diff	契约是 JSON，两次改动之间能看出改的是 tactics 还是 forbidden
可对账	库里只存 `{id, version, digest}`，读侧按同样输入重算，指纹不一致就显示「契约已漂移」
可渲染	System Prompt 由 `renderSystemPrompt(contract)` 确定性渲染，同样契约永远得到同一份提示词

第 4 条是本项目的一个明确取舍，也是设计上最值得讲的一处。

2.3.3 契约不落库全文，只落指纹

要做「契约可见」，最省事的做法是把契约 JSON 存进会话表，读出来显示。本项目没有这么做。

库里只存三样：

```
{ id: 'tech', version: 1, digest: '042b385f925cf50f' }
```

读侧每次按同样输入（面板 + 预算）**重新计算**契约全文，再用指纹与库里那一份对账：

```
const verified = match !== undefined
  && match.digest === digest
  && match.version === contract.version;
```

理由是「存副本」会把一句无法验证的断言混进产品：代码改了契约之后，老会话显示的仍是旧副本， 而旧副本已经不在任何地方运行了——**观众看到的和实际跑的不是同一份东西，且没有任何信号提示。**

重算 + 对账把这件事变成可判定的状态。界面上只有两种结论：

状态	界面文案	含义
一致	与运行时一致 · 指纹 b2171c82	现在这份契约就是跑这一场时用的那份
漂移	契约已漂移 · 运行时 a1b2c3d4 → 现在 b2171c82	代码改过契约，这场会话用的是旧的
未开跑	尚未开跑 · 当前指纹 b2171c82	还没跑，无从对账

这个取舍的一般化结论写在 `findings.md` 的 F19 里： **凡是「实现里有一份、展示里又抄一份」的数据，都该改成「一份真值 + 一个指纹」。**

2.3.4 契约的渲染：System Prompt 的六节结构

模型实际拿到的不是上面那段 JSON，而是由它确定性渲染出的六节提示词。以技术面试官为例（真实输出，界面截图 10-system-prompt.png 就是它）：

节	作用	是否可被程序校验
你这一场的目标	告诉它「为什么问」	否（属于意图）
可用手法	给出三条具体战术，避免泛泛而问	否
硬约束（由程序强制校验，违反的提问会被丢弃）	四条必须满足的条件	**是**（L2 锚定 + 去重）
禁止	四条禁区	部分
追问预算（由程序记账，你不需要自己记）	三条上限	**是**（L3 记账）
输出要求	精确的 JSON 形状	**是**（zod）

注意「硬约束」与「追问预算」两节的标题措辞：它们明确告诉模型「这件事由程序负责」。 这不是修辞——它减少了模型在边界上的试探，因为模型知道越界会被直接丢弃，而不是被商量。

2.4 L2 校验层：证据锚定，让提问可证伪

2.4.1 规则

每条提问必须携带一个 `quote`，它是**从简历里逐字复制的片段**。程序做三件事：

1. 先做逐字查找（`source.indexOf(quote)`），命中即 `exact: true`；
2. 失败则做归一化查找（全半角标点映射 + 空白折叠 + 小写），命中则 `exact: false`；
3. 两者都失败 → 这条提问被丢弃，理由写进「被拦下的追问」，**不消耗预算。**

锚点的坐标由程序用 `source.slice(start, end)` 算出来，**不采信模型给的 start/end。** 这条决定记在决策表 D7：模型给的偏移量只当提示，坐标以引文回原文重新定位为准。

2.4.2 四种拒绝理由

拒绝码	中文标签	触发条件
empty-quote	引文为空	模型没给 quote
too-short	引文太短	少于 4 个字符（短引文能在简历里命中任何地方，等于没锚定）
quote-not-found	引文在简历里找不到	模型改写了原文、补了标点、或编了一句
out-of-range	区间越界	计算出的区间超出简历长度

2.4.3 为什么这条规则是全部创新点的地基

「提问必须锚定原文」把一句主观判断（这个面试官问得好不好）变成了一句客观判断（**这个问题有没有证据**）。 它带来三个连锁效果：

- **幻觉式提问被物理消灭**：模型编一句「你在某大厂做过高并发」是过不了锚定的，因为简历里没有这句话。
- **界面可以拒显**：没有锚点的提问不会进入事件日志，因此也不会进入界面。
- **追问变得可评估**：每条提问都指向一个具体的简历片段，因此「这条主张被问了几次、问到什么程度」是可统计的。

第三个效果直接引出下一层。

2.5 L3 记账层：追问预算，让死循环在设计上不成立

2.5.1 问题

多 Agent 追问最常见的失败形态是**不收敛**：A 问完 B 换个角度问，B 问完 A 再追一层， 每一轮都「还有可以问的」，于是永远停不下来。提示词里写「最多 3 次」拦不住它。

2.5.2 做法

把追问次数做成一个**不可变的账本**（`packages/shared/src/budget.ts`），每次提问前必须过闸门，通过才记账：

```
export interface BudgetConfig {
  maxRoundsPerClaim: number;              // 同一条主张全场最多追问几轮
  maxProbesPerInterviewerPerClaim: number; // 每位面试官对同一条主张最多问几次
  maxTotalProbes: number;                  // 全场追问总次数上限
  maxConsecutiveUnanswerable: number;      // 连续几次答不上来就关停这条主张
}

export const DEFAULT_BUDGET: BudgetConfig = {
  maxRoundsPerClaim: 3,
  maxProbesPerInterviewerPerClaim: 2,
  maxTotalProbes: 60,
  maxConsecutiveUnanswerable: 2,
};
```

闸门 `canProbe(state, claimId, interviewerId)` 按固定顺序做五道检查，**任何一道不过就拒绝，并给出可直接展示给用户的中文理由**：

顺序	检查	拒绝理由（原文）
1	主张是否存在	该主张不在本次沙盘中
2	主张是否已关停	关停理由，或「该主张已关停」
3	全场总次数	已达全场追问上限 60 次
4	该主张轮数	该主张已达追问轮数上限 3 轮
5	该面试官额度	该面试官对这条主张的提问额度已用完

顺序不是随意的：先判「这条主张还值不值得问」，再判「全场还有没有预算」，最后才判「这位面试官还有没有额度」。 这样拒绝理由总是最有信息量的那一条。

2.5.3 关停：连续答不上来就止损

账本还负责一件事：如果求职者连续 2 次答不上来同一条主张，这条主张被自动关停，理由写进账本：

> 已连续 2 次答不上来，继续追问没有信息增量

关停之后这条主张从「可追问清单」里消失（简历原文当然还是整份给模型），后续轮次不会再为它发起调用。 这条规则同时解决了两个问题：用户体验（不反复羞辱同一件事）与成本（不为已知结论烧 token）。

2.5.4 追问强度：换的是预算，不是人设

预算对用户可见，所以它必须可调：界面上有温和 / 常规 / 挑刺三档，落成三组不同的上限（每主张 2 / 3 / 4 轮、 每人每主张 1 / 2 / 2 次、全场 40 / 60 / 80 次）。三档只改**预算块**：人设、目标、手法、禁区一字不动。 理由是意图控制的一条边界——人设一改，两场之间的说法就不可比，「这个人比上次问得狠」这种判断失去意义； 而预算改了，契约指纹跟着变，界面会如实显示「当前指纹 cf9c6457」（挑刺档），换个档再换回来又回到原指纹。 档位随会话落库（`session.meta.difficulty`），重开一场历史会话仍看得出这一场问得多狠（决策 D46）。

代价很具体：契约是卡带指纹的输入，档位一变指纹就变，所以离线演示按三档各录了一份卡带（149 盘里占 3 份）。 这与「改提示词必须重录」是同一条规则，只是这次变的输入来自界面而不是代码。

2.5.5 编排层的收尾条件

编排循环的条件是：

```
while (rounds < maxRounds && probeableClaims(budget, panel).length > 0) { ... }
```

这里有一个容易写错的地方值得写进文档：一开始用的是 `openClaims(budget).length > 0`，而 `openClaims` 只表示「主张没有被 close」——额度用尽的主张仍然算 open，于是编排器会白烧一轮空的模型调用（live 模式是真金白银）。为此新增了 `probeableClaims(state, interviewerIds)`：**存在至少一位面试官能通过 `canProbe` 的主张。**

另外，如果一轮下来所有面试官都没有提出任何新问题（都被去重闸门拦了），编排器直接收尾并写一条如实记录的提示：

> 第 3 轮没有任何新的追问，质询到此结束

这条提示会出现在报告里，也会出现在界面的事件日志里——**收敛是可见的，不是悄悄结束的。**

2.6 L4 收敛层：模型给的判定与建议，还要再过一遍代码

2.6.1 判定阶段的两条收敛规则

模型判完之后，`enforceVerdict` 会用两条确定性规则复核（`verdict.ts`）：

规则	条件	处理	理由文案
全没答上来还判「站得住」	有追问，所有追问的回答都无效，且模型判「站得住」	降级为「证据缺失」	候选人对这条主张的追问没能落出口径，原文这一句不足以判为「站得住」，按「证据缺失」处理
要证据却拿不出	判为「站得住」或「与原文矛盾」，但证据引文一条都定位不到	降级为「证据缺失」	模型判为「站得住」但模型拿不出可定位到简历原文的证据，按「证据缺失」处理

第二条尤其重要：**「站得住」是一个需要证据的结论。**模型想判 solid，就必须拿出能在简历里定位到的引文；拿不出，这个判定就不成立。这与 L2 的锚定是同一个思想，只是从「提问」延伸到了「结论」。

第一条只做一件事：**防止过于乐观**，而不是替模型决定责任归属。代码手里只有一个布尔（这一场有没有答上来过），而模型看得见每一轮问答——它比这个布尔更清楚该算「简历写得太笼统」（证据缺失，改简历就行），还是「候选人自己拿不出东西」（无法回答，风险最高）。把「全体未答」一律改判「无法回答」的版本犯过一个真实错误：模型的理由里明明白白写着「只有结论、没有口径，属证据缺失」，界面上却挂着「无法回答」的徽章——理由是模型写的，结论是代码改的，两者当场矛盾（真实联网运行时才发现，见 5.6 第 5 条）。

为了让这两档可判别，`VERDICT_SYSTEM` 把判据写成了**责任在谁**：证据缺失 = 简历的错（这句话写得太笼统，改法是把口径写进去）；无法回答 = 人的错（本人承认不记得、举不出例子、没做过，面试现场会直接翻车）。拿不准时判「证据缺失」——它是一个可执行的结论，指向改简历；误判「无法回答」会让人以为这段经历该删掉。

被代码改过的判定会在界面上带一条琥珀色说明：「这条判定不是模型直接给的」+ 具体理由。截图 06-verdicts.png 里的 C5 就是这种情况。

2.6.2 建议阶段的四道闸门

改写建议是最容易被模型「发挥」的环节——它会顺手帮你加一个更漂亮的数字。因此 `suggest.ts` 设了四道闸门，任何一道不过，这条建议被拒绝并记录原因：

闸门	检查	拒绝理由
是否需要建议	判定为「站得住」的主张直接跳过（不调用模型、不消耗预算）	判定为「站得住」，不需要改写
改前原文可定位	`before` 必须能在简历里锚定到	建议里的「改前原文」在简历中定位不到，无法应用
不许引入新事实	`after` 里的数字必须是简历里已有的数字	建议里出现了简历原文中不存在的数字，属于新增事实
必须真的改	`after` 不能为空，也不能等于 `before`	建议改写后与原文相同，等于没改

第二道闸门的具体实现是 `newNumbersIn(after, resumeText)`：用正则 `/[0-9]+(?:\.[0-9]+)?/g` 抠出建议里的所有数字，逐个检查是否在简历原文的数字集合里出现过；只要有一个新的，整条建议作废。

这条规则的效果可以在离线演示里直接看到：C2 的改写建议里出现的 `800` 与 `5000` 都来自简历原文，模型没有机会把「QPS 5000」改成「QPS 8000」。

2.6.3 归属由调用方决定

建议的归属（这条建议属于哪条主张）**一律由调用方传入**，模型自报的 `claimId` 不看。这一条在 live 实测里救过一次命：schema 曾把 `claimId` 列为必填，而提示词从没要求模型输出它，于是 9 条建议全部因「claimId: Required」被拒；离线演示恰好写了这个字段，把矛盾完整掩盖。修复后 `claimId` 改为 optional，并补了「模型不返回 claimId 也能出建议」的回归测试。

这个 bug 的教训写在 `findings.md` F23，也是本文档第 5.6 节要展开的「给模型输出造夹具的唯一真相是提示词里的输出要求」。

2.6.4 改写风格：调的是措辞收敛程度，不是事实边界

同一个毛病，有人想改得稳一点，有人想改得狠一点。所以改写阶段多了一个用户可选的档位：

档位	界面名	提示词里的取向	典型产出
`conservative`	保守	只做减法：删掉没依据的形容词，宁可句子变短变笨	删掉「大幅」「显著」这类词，保留原句式
`normal`	常规	该收敛的收敛，该补口径的补口径	给结果补上测量条件
`bold`	敢改	重写整句，但**不新增任何事实**	把「优化了性能」重写成具体的「把首屏从 2.4s 降到 0.8s（同一套压测口径）」

三档**只改措辞的收敛程度**。2.6.2 那四道闸门在任何档位都不放宽，尤其第三条「不许引入新事实」—— `bold` 档最容易被模型当成「可以自己润色」的许可，所以它的档位说明里直接把「不新增任何事实」写死， 并且 `newNumbersIn` 照样在代码里逐条核对：模型说它没加数字不算数，代码认可才算数。

两个刻意的设计：

选择	为什么
档位**不进契约指纹**	契约描述的是「谁在问」，风格描述的是「改得多狠」，两者是不同维度的意图。混进同一个指纹，会让「换了风格」看起来像「换了面试官」，历史场次之间就没法比了（追问强度的做法相反：它改的就是预算，就在契约里，见 2.5.4）
档位随 `session.meta.style` 落库	报告是被带走的产物。抬头不写明这一场是「敢改」还是「保守」，两份报告摆在一起时，建议强弱不同就变得不可解释

代价与追问强度同源： `suggest` 提示词里带着档位，档位一换指纹就换，所以离线演示的 suggest 卡带要从 4 盘变成 12 盘（4 条建议 × 三档）。 这是「提示词是输入，输入变了素材就失效」这条规则第二次收账，也被记录在 ADR-0017 里。

2.7 过程可视化：流式分片是观感，事件日志才是真相

赛题的 UX 评分项明确点名了「流式、思考可视化」。本项目的处理方式是一条明确的分界：

	流式分片	阶段事件
内容	模型正在吐的字符	阶段开始 / 主张列表 / 追问列表 / 判定列表
落库	**否**	是（带 seq）
可断线续传	否（刷新就没了）	是（`?from=<seq>`）
界面位置	卡片内的「正在作答」「正在定级」+ 过程面板的「实时输出」	阶段时间线

实现方式是给 LLM 客户端套一层 `withStreaming(inner, sink)`：各阶段的编排代码照旧 `await client.complete()`， 包装层把它改写成 `for await (inner.stream(req))`，把 `delta` 与 `reasoning` 分片送进 sink，最终结果取自 `done` 事件。 分片通过 SSE 的 `event: stream` 送出，**不带 id、不占 seq、不进事件表。**

理由写在 ADR-0004 里：分片每秒几十片，落库会让回放变慢、日志变吵，而分片拼出来的文本并不比 done 事件更可信。**能断线续传的只有阶段事件——这是「可复现」与「好看」之间的一条明确分界。**

顺带一个工程细节：分片携带的 `channel` 字段（例如 `answer:P1`、`verdict:C3`）**刻意不参与卡带指纹**， 因为指纹只对请求做哈希（system / messages / temperature / maxTokens / json）。 这条设计让「加流式」这件事不需要重录任何一盘离线卡带。

2.7.1 思考分片：接上会思考的模型，界面上多一行斜体

思考（`reasoning`）与正文（`delta`）是两个独立通道，用分片上的 `kind` 区分；界面渲染成两行—— 斜体那行是它正在「想」的，正下方那行是它要「说」的。要让这一行真的出现，需要三件事：

环节	做法	为什么
选谁思考	装配层 `withStageModels(inner, routes)`，按 `req.purpose` 换模型	判定才需要「停下来想」；追问一轮十几次调用，全交给思考模型会把一场从十几秒拉成几分钟（ADR-0005）
换模型不发卡带	`LlmRequest.model` 与 `channel` 一样不参与指纹	已录好的 149 盘演示卡带不必重录
没有 Key 也看得见	合成脚本把 `reasoning` 写进卡带（同一个通道）	离线演示也要能证明「思考可视化」是产品能力，不是联网才有的彩蛋；卡带 `model` 固定 `scripted-demo`，一眼可辨

实测（2026-10-26，示例简历， `CROSSEXAM_REASONING_MODEL=deepseek-reasoner` 只路由 verdict）： 一场得到 **2,355 片思考分片 / 8 路 `verdict:*` 通道**，账本 `reasoningTokens` 大于 0，同一场正文分片 5,814 片，两条通道都不进事件表。 一条

要如实说明的代价：模型给的思考文本通常是**英文**（如 “The user asks: …”），这是模型侧行为，我们不翻译——硬翻译会让「思考」变成另一种编造。

2.8 本章要点

- 意图控制不是写提示词，是**四层可判定的机制**：声明（契约）→ 校验（锚定）→ 记账（预算）→ 收敛（规则）。
- 每条提问必须锚定简历原文，这是「提问可证伪」的地基，也是幻觉提问被物理消灭的原因。
- 追问预算由代码记账而非模型数数，因此死循环在**设计上**不成立，而不是「我们尽量避免了」。
- 判定与建议都要过代码复核：模型想判「站得住」必须拿出证据；想改简历不许引入新数字。
- 给用户的旋钮只调「程度」，不调「规则」：追问强度改预算不改人设，改写风格改措辞收敛不改事实边界。
- 契约不落库全文，只落指纹，读侧重算对账——一份真值 + 一个指纹，胜过两份迟早不同步的副本。

第三章　架构设计

3.1 一条约束决定了整个架构：服务端不设构建步骤

赛题 25% 是「过程可复现性与演进链路」。对一份要交给评委复现的项目来说，**每一个「先做 A 才能做 B」的步骤都是一个失败点**：

常见步骤	失败方式
先装编译器 / 编译原生依赖	Windows 上 node-gyp 失败、Python 版本不对
先 build 后端再 run	忘了 build、build 产物过期、build 报 TS 错误
先装 Docker	评委机器没装或没权限
先申请 API Key	没有卡、没有额度、区域不支持
先建数据库	忘了迁移、路径没权限

本项目把上表里能消灭的全部消灭了，得到一个极短的复现路径：

```
git clone  →  npm install  →  npm run preview  →  打开浏览器  →  点两下
```

其中最关键的一条决策是 **ADR-0001：服务端不设构建步骤，直接用 Node 原生 TypeScript 运行。**

3.1.1 为什么这条能成立

Node 22.6+ 提供类型剥离（type stripping），可以直接运行 `.ts` 文件。但有一条众所周知的限制：**类型剥离默认不作用于 node_modules 内的文件。** npm workspaces 的包在 `node_modules/` 下是符号链接，因此理论上 `import '@crossexam/shared'` 会被当作「node_modules 内的模块」而拒绝剥离。

这个假设在 P1 阶段用一条最小验证钉死了（`.tmp/node-smoke.mjs`，纯 `node` 运行）：

验证项	结果
`import '@crossexam/shared'` 拿到 46 个导出	成功
直接 import `replay.ts` / `cassette.ts`	成功
跨包调用 `buildContracts(['tech','hr'], ...)`	返回 2 条契约
`chunkText` 分片后拼接	与原文逐字相等

原因是 Node 会先 realpath：符号链接解析后文件真实位置在 `node_modules` 之外，于是类型剥离正常生效。 **这条假设不是查文档查来的，是实测出来的**——这也是本文档反复强调的方法：凡是架构依赖的前提，都要有一条可复跑的最小验证。

3.1.2 代价与边界

代价	处置
不能用 TS 的装饰器 / enum 等需要转译的语法	代码里本来也不用
类型检查与运行分离（运行时不做类型检查）	`npm run typecheck` 单独跑 `tsc --noEmit`，纳入提交门禁
生产部署不适合	本项目是本地优先的桌面级工具，不做服务端部署
前端仍需构建	前端是浏览器代码，必须 Vite 构建；但只有一条 `npm run build`

3.2 模块划分

```
D:\CZB
├── packages/
│   ├── shared/          领域模型与纯函数内核（零依赖、无 IO、100% 可单测）
│   │   ├── domain.ts        领域类型：Claim / Probe / Answer / Verdict / Suggestion
│   │   ├── anchor.ts        证据锚定：引文 → 字符区间
│   │   ├── segment.ts       简历确定性切分：小节 / 条目 / 段落
│   │   ├── budget.ts        追问预算账本（不可变）
│   │   ├── contract.ts      意图契约与确定性提示词渲染
│   │   ├── schemas.ts       模型输出的 zod 契约与解析
│   │   └── util.ts          确定性 id、稳定序列化、哈希
│   │
│   ├── server/          编排与 IO
│   │   ├── llm/             LLM 适配层：live / record / replay 三态 + 卡带 + 流式包装
│   │   ├── orchestrator/    九阶段：extract / jd-extract / jd-merge / jd-match /
│   │   │                    probe / answer / verdict / suggest / counter + run 编排
│   │   ├── store/           node:sqlite 建表、迁移与仓储
│   │   ├── http/            Hono 路由 + SSE + 静态托管
│   │   ├── pipeline.ts      编排 → 落库 → 视图 的一体化入口
│   │   ├── report.ts        Markdown 报告渲染
│   │   └── bin/serve.ts     服务入口
│   │
│   └── web/             Vite + React 19 + Tailwind v4
│       ├── api.ts           HTTP 契约与 SSE 解析
│       ├── state.ts         事件流折叠成界面状态的纯函数
│       ├── labels.ts        文案（与 shared 的漂移由测试看守）
│       └── components/      五栏界面（右栏简历 / JD 分屏）
│
├── tools/
│   ├── dsh-export/      DSH 会话日志 → Prompt 链快照（提交物 #2 的生成器）
│   ├── smoke/           真进程冒烟（起服务、打接口、等 SSE 收尾）
│   ├── ui-shots/        无头浏览器截图器，兼作控制台报错门禁
│   ├── repro/           干净目录复现预演
│   └── docs/            Markdown → HTML → PDF 技术文档构建
│
├── fixtures/llm/        149 盘离线卡带（按提示词指纹寻址）
├── docs/                ADR / 技术文档 / 截图 / Prompt 链快照
└── data/                运行时 SQLite（已 gitignore，含用户简历隐私）
```

3.2.1 划分原则：按「依赖方向」而不是按「技术层次」

包	允许依赖	禁止依赖	理由
shared	只有 Node 标准库（`node:crypto`）	任何 IO、任何网络、任何数据库	纯函数才好测；937 行源码配 489 行测试
server	shared + Hono + zod	不依赖 web	服务端不知道前端长什么样
web	React + 自己的 api.ts	**不 import @crossexam/shared**	见 3.4

shared 里唯一的 IO 痕迹是 `util.ts` 的 `node:crypto`（算哈希），这一处恰好是 web 不能直接引 shared 的原因，也解释了为什么 web 要抄一份文案再用测试守住（3.4 节）。

3.3 LLM 适配层：一个接口，三种实现，一条卡带

3.3.1 接口

```
export type LlmMode = 'live' | 'record' | 'replay';

export interface LlmClient {
  readonly mode: LlmMode;
  complete(req: LlmRequest): Promise<LlmResult>;
  stream(req: LlmRequest): AsyncIterable<LlmStreamEvent>;
}
```

三个模式共用同一个请求结构，差别只在「结果从哪来」：

模式	结果来源	用途
live	真实 HTTP 调用	联网跑，用户填了 Key 时
record	真实 HTTP 调用 + 落盘成卡带	录制演示素材
replay	从卡带读	**默认模式**，评委零配置跑通全流程

3.3.2 卡带：用提示词指纹寻址

卡带（cassette）是一份 JSON 文件，文件名是提示词的指纹：

```
const digestFor = (req: LlmRequest) =>
  shortHash(stableStringify(shapeOf(req)), 24);

// shapeOf 只取这五项：
// { system, messages: [{role, content}], temperature, maxTokens, json }
```

刻意不包含模型名与 purpose。理由是换模型不该让整盘卡带失效——同一份提示词问出来的东西， 在演示意义上等价于同一段素材。这条决策也解释了为什么「加流式」不需要重录（channel 不在指纹里）。

回放客户端的失败方式是**响亮的**：

```
LlmError: 回放模式找不到这一条记录。用途「extract」的指纹是 b1206dc35699453a6dfbaa28，
请用 CROSSEXAM_MODE=record 联网跑一次把它录下来。
```

绝不静默降级到「跳过这一步」或「返回空结果」。这条选择在 `findings.md` F12 里有完整教训： 录制端第一版因为逐项容错，跑完 exit 0 但只写出 16/27 盘卡带，10 条回答全部缺失，stderr 干干净净。

3.3.3 记账包装：任何客户端都被套一层

```
withAccounting(inner, { db, sessionId, model })
```

它把每一次调用记进 `llm_call` 表：指纹、用途、模型、是否回放、四类 token、耗时。 界面顶部的「调用 29 次 · 回放 29 · token 23,533」就来自这里。 这层包装同时解决了两个问题：成本可见（live 模式知道花了多少）与**可复现性可见**（回放模式下「调用 N 次 / 回放 N 次」直接证明这一场没有联网）。

3.3.4 流式包装：只在需要直播时才套

```
const base = input.onStream === undefined
  ? input.client
  : withStreaming(input.client, input.onStream);
```

各阶段的编排代码完全不知道流式的存在（它们照旧 `await client.complete()`）。 好处是：JSON 路径（`?stream=0`）与 SSE 路径共用同一份编排逻辑，两条路径都被测试覆盖，且不会出现「流式版本和普通版本行为不一致」。

3.3.5 阶段路由：换模型是装配层的事

```
withStageModels(inner, { verdict: 'deepseek-reasoner' })
```

编排层只关心「问什么」，用哪个模型是装配层的事：`withStageModels` 按 `req.purpose` 在请求上带一个 `model` 字段， 各阶段的代码一行都不用改。默认只把**判定**交给思考模型（`CROSSEXAM_REASONING_STAGES` 可改）， 理由见 ADR-0005：判定才需要「停下来想」，而追问一轮要十几次调用。 `LlmRequest.model` 与 `channel` 一样**刻意不参与卡带指纹**，所以换模型不必重录任何一盘离线卡带。

3.4 前端形态：为什么 web 不 import shared

这是一个看起来违反直觉的决策（共享类型不是好事吗？），但有一条硬理由：

shared 经 `util.ts` 依赖 `node:crypto`，把它引进浏览器包会污染打包结果。 备选方案是把 shared 拆成一个零依赖的 core 包——这在架构上更干净，但会引入一次全仓库重构， 而本项目的时间预算要留给「意图控制」与「可复现性」。因此本项目选择：**类型与文案各抄一份，用测试守住漂移。**

3.4.1 漂移怎么守

会漂移的东西	守它的测试	断言方式
五种判定的中文标签	`packages/web/test/labels.test.ts`	`toBe`（同一个对象，不是相同内容）
七种主张类别	同上	逐项对照 + 顺序不漏不重
五类人设的名字与简介	同上	逐字对照 `PERSONA_PRESETS[role].persona`
高亮区间的切分逻辑	`packages/web/test/highlight.test.ts`	9 条边界用例
事件折叠成界面状态	`packages/web/test/state.test.ts`	同一串事件喂给直播路径与历史路径，断言结果完全一致

最后一条是整个前端设计里最关键的一条：

> **直播与历史共用同一个纯函数折叠器**（ADR-0003）。

直播是把 SSE 事件一条条喂进去，历史是把库里的事件按 seq 读出来再喂进去， 两条路径的结果必须逐字段相同（除了 `phase` 由来源决定）。 这条测试保证了一个常被忽略的产品承诺：**刷新页面之后看到的，和刚才实时看到的，是同一场。**

3.4.2 界面结构：五栏 + 一条时间线

栏	内容	对应评分项
左：输入与过程	简历输入、岗位 JD（1–8 份）、节奏控制、运行模式、意图契约、阶段时间线、实时输出、统计	意图控制（契约可摊开）
中上：主张与追问	每条主张一张卡片：原文引文、追问链、作答、判定、改写建议	实用价值（结论定位到字）
中中：岗位要求对照	每条岗位要求一张卡片：要求正文、引文、「为什么这么判」、对应哪条主张	实用价值（岗位要求也落到字）
中下：轮到你了	几句可以反问 HR 的话，每句带简历或 JD 原文依据，并写明回答是沙盘模拟的	实用价值（材料反着用一次）
右：简历原文 / 岗位要求原文	左右分屏，两边都能点引文聚焦到具体字符区间，用的是同一套聚焦机制	证据锚定（两处锚都看得见）
顶：状态条	模式、调用次数、回放次数、token、事件数、追问数	可复现性（回放可见）

3.5 存储：node:sqlite，零原生依赖

选 `node:sqlite`（Node 24 内置）而不是 better-sqlite3，理由只有一个：**不引入需要本地编译的原生依赖。** 这条约束写进了 `AGENTS.md` 第 6 节：破坏「10 分钟复现」的依赖需要 ADR 才能进。

3.5.1 三个必须知道的差异（实测，记在 findings F8）

差异	后果	处置
外键约束按连接生效	漏发 PRAGMA 会安静留下孤儿数据	`openDatabase` 里固定发 `PRAGMA foreign_keys = ON`
`prepare().all()` 返回 `unknown[]`	每处用法都要断言	仓储层用一个私有辅助函数收口（断言会绕过类型检查，收口不会）
`PRAGMA user_version` 现成可用	不需要自建版本表	迁移直接用它做版本位

3.5.2 迁移：三条教训变成三条规则

规则	来源
连接即建表（readonly 除外）	F11：同进程测试全绿，真起服务第一次写入报 `no such table: session`
迁移步骤冻结在自己时点，不引用当前 DDL	F24：v1→v2 若用当前 DDL，会一步建成 v3 表却把 user_version 写成 2
库版本比代码新时拒绝启动	防止老代码写新库，把数据写坏

当前 `SCHEMA_VERSION = 9`，表结构：

```
session(id, createdAt, updatedAt, llmMode, jobTitle, jdText, resumeText,
        resumeHash, status, budget_json, meta_json)
jd(session_id, id, ordinal, title, text)   PRIMARY KEY (session_id, id)
claim(session_id, id, ordinal, text, start, end, quote, exact, category,
      weight, status, verdict)          PRIMARY KEY (session_id, id)
probe(session_id, id, claim_id, interviewer_id, round, question, rationale,
      quote, start, end, parent_probe_id, requirement_id, jd_quote, jd_start,
      jd_end, jd_exact, answer_text, answer_mode, answer_cites_json, verdict)
                                        PRIMARY KEY (session_id, id)
requirement(session_id, id, ordinal, kind, text, keywords_json, jd_id,
      sources_json, quote, start, end, exact)  PRIMARY KEY (session_id, id)
requirement_match(session_id, requirement_id, claim_id, status, reason)
                                        PRIMARY KEY (session_id, requirement_id)
interviewer(id, version, digest, source, domain, contract_json,
      created_at, updated_at)           PRIMARY KEY (id)
revision(session_id, ordinal, claim_id, start, end, before, after, created_at)
                                        PRIMARY KEY (session_id, ordinal)
revised_resume(session_id, text, digest, accepted_json, pending_json,
      skipped_json, created_at, updated_at)    PRIMARY KEY (session_id)
supplement(session_id, claim_id, text, digest, created_at, updated_at)
                                        PRIMARY KEY (session_id, claim_id)
counter(session_id, id, ordinal, text, kind, reason, reply, source, jd_id,
      quote, start, end, exact, created_at)    PRIMARY KEY (session_id, id)
event(session_id, seq, kind, payload_json, createdAt)
llm_call(id, session_id, digest, purpose, model, replayed, usage_json, elapsedMs, createdAt)
```

会话相关的表都挂着 `session_id` 外键并级联删除：删掉一场会话不会留下孤儿行。`interviewer` 是唯一的**全局表**—— 它是一间面试官库，不属于任何一场会话；但一位面试官一旦被某场会话引用，它的 id、版本与指纹就冻结在那场会话的 `meta_json` 里，之后在库里改了或删了，旧会话的复现与对账仍然成立（第 3.6.6 节）。

复合主键（`session_id, id`）是 v2 迁移引入的。原因很具体：主张编号每场会话都从 `C1` 重新开始， 全局唯一主键会让同进程第二场会话直接撞 `UNIQUE constraint failed: claim.id`。

`revision` 的主键在 v8 从 `(session_id, claim_id)` 换成了 `(session_id, ordinal)`：P10 之后同一条主张可能同时落下两条改动—— 一条替换（改写建议）加一条零宽插入（用户补的那句真话），旧主键会让第二条把第一条覆盖掉。 `counter`（反问）与 `supplement`（补充说明）都是 v9/v8 新增的表，前者整批替换、后者只存那句话本身。

3.6 HTTP 层：一个端口，两种响应

接口	用途
`GET /api/health`	模式、跑法、模型、卡带目录，以及可选运行模式清单与「联网是否配好」
`GET /api/models`	联网模式下可用的模型清单（配不全时**一个网络包都不发**，直接返回缺哪个环境变量）
`GET /api/demo`	内置示例简历与 JD
`POST /api/import`	上传 PDF / Word / 文本，解析成简历正文（字节不存留；413 太大 / 415 格式不支持 / 422 解析不出文字）
`GET /api/contracts?panel=`	意图契约全文 + 指纹（纯确定性，不调模型、不读库）
`GET /api/interviewers`	面试官库：五位预设（只读）+ 自建的那些（带 id / version / digest / 渲染出的 System Prompt）
`POST /api/interviewers/draft`	把一句话描述补成契约草稿（**不落库**）：`useModel:false` 走本地规则，模型失败自动退回本地并说明原因
`POST /api/interviewers`	保存自建面试官（预设不可改、不可删）
`DELETE /api/interviewers/:id`	删掉一位自建面试官（预设返回 400，不存在返回 404）
`GET /api/templates`	岗位模板库：12 个行业 × 3 个岗位，每条含 JD、示例简历、可追问点与推荐的两位面试官（只读，**不写任何表**）

接口	用途
`POST /api/templates/:id/apply`	一键采用：把 JD 与示例简历填进投料台，并把模板自带的那位面试官装进库里（按模板 id 派生 id，**幂等**；返回 `created` 说明是新建还是复用）
`POST /api/sessions`	建档（useDemo 或 resumeText，可指定 `mode`、`model`、`interviewers`，以及 `jds`——1–8 份岗位 JD：这些选择都随会话落库）
`POST /api/sessions/:id/run`	跑沙盘：默认 SSE 直播，`?stream=0` 走 JSON
`GET /api/sessions/:id/events?from=`	事件续传
`GET /api/sessions/:id/report.md`	下载 Markdown 报告（采纳过改写就多一节「改前改后对照」）
`GET /api/sessions/:id/report.html?print=1`	可打印 HTML 报告（`print=1` 时自动调 `window.print()`，PDF 由浏览器另存；采纳过才带并排对照表）
`GET /api/sessions/:id/report.doc`	Word 报告（同一份 HTML + `application/msword`，同上）
`POST /api/sessions/:id/supplements`	记下某条主张的补充说明（一句真话）：只存那句话与指纹，**不存坐标**——插入点由主张的锚点现算
`DELETE /api/sessions/:id/supplements/:claimId`	删掉这条补充说明（没记过返回 404）
`GET /api/sessions/:id/revisions`	当前采纳出来的那一版简历（没采纳过是 `null`）
`POST /api/sessions/:id/revisions`	确认采纳：body 里的 `claims` 是**本次勾选的全部主张**，不是增量
`DELETE /api/sessions/:id/revisions`	撤销全部采纳，回到原文
`GET /api/sessions/:id/resume.txt`	改完的简历（纯文本，逐字就是要发出去的那一版）
`GET /api/sessions/:id/resume.html?print=1&marks=1`	可打印简历（`marks=1` 把改动段标绿并附「本版改了什么」）
`GET /api/sessions/:id/resume.doc`	Word 简历（同一份 HTML + `application/msword`）
`GET /api/stats?session=`	调用账本统计

3.6.1 SSE 的收尾承诺

SSE 有三个终止事件，任何一个发生都意味着这一场结束了：

事件	含义
`result`	正常跑完，附小结
`fatal`	致命失败（例如回放模式缺卡带），附原因
连接关闭	客户端断开

「一定会以成功或明确失败收尾」这条承诺由真进程冒烟守着（`tools/smoke/smoke.mjs` 会等 SSE 收尾并断言收到了 `result` 或 `fatal`）。

3.6.2 单端口托管前端

`mountWebApp(app, distDir)` 在 `/api/*` 之外挂静态托管 + SPA 回退。 这样评委只需要打开一个地址，不需要记两个端口，也不会有跨域问题。 服务入口用 `new URL('../../../web/dist', import.meta.url)` 定位前端产物，**因此从任何工作目录启动都能找到。**

3.6.3 报告导出：服务端出 HTML，PDF 交给浏览器

同一份 `SessionView` 有三种呈现：Markdown（`report.ts`，便于携带与 diff）、可打印 HTML（`report-html.ts`，便于阅读与打印）、 Word（`.doc` 后缀 + `application/msword`，便于接着改）。**服务端不生成 PDF**：那需要带一个无头浏览器或 PDF 库， 前者把「十分钟复现」变成赌评委机器上装了什么，后者违反零原生依赖。取舍详见 ADR-0006。

HTML 报告不引用任何外部资源，保存单文件即可离线打开；页脚写明「简历与报告都没有离开这台机器」。 打印脚本只在 `?print=1` 时注入——默认打开不会突然弹打印对话框（有测试守住）。

3.6.4 简历导入：解析成文本，但不留档

`POST /api/import` 只做一件事：把上传的字节变成简历正文，填进投料台的输入框，然后**字节就被丢掉**—— 不写临时文件、不入库、不进日志。于是「简历没有离开这台机器」在导入这条路径上也成立（上传的字节连磁盘都不落）。

解析按格式分三条路，每条都尽量少欠依赖：PDF 用 `unpdf`（纯 JS，零原生编译），`.docx` 自己解 zip（`node:zlib` 的 `inflateRawSync` 拆出 `word/document.xml`，不引 SDK），纯文本先按 UTF-8 解、出现替换字符再试 GBK （中文简历的现实

情况）。老版 `.doc` 是二进制复合文档，明确拒绝并提示另存为 `.docx`——**宁可给一句可执行的话，也不给一段看起来像正文的乱码。** 选型对比与三个反直觉的 PDF 行为见 ADR-0007、findings F39；导入器自己有 11 条单测，HTTP 分档另有 4 条。

3.6.5 运行模式与模型：逐场选，且随会话留档

三种模式（离线回放 / 联网直连 / 联网录制）在**页面里逐场选择**，选择结果写进会话行：`llmMode` 落模式，`meta.model` 落模型名。跑的时候按会话行建客户端——单一事实来源在库里，不需要内存里的映射表，翻回一周前的会话也能说清它当时是怎么跑出来的。

`GET /api/models` 只在显式选择联网后才被前端调用：先 `resolveLiveConfig`，缺 `LLM_BASE_URL` / `LLM_API_KEY` 就**一个网络包都不发**，直接把缺哪个变量告诉界面。拉不到清单不等于不能用——界面是 `input + datalist`，可以手填模型名；`/models` 返回什么也**不是可用性证据**（本机实测它只列出两款模型，而实际能调通四款）。见 D33、D34、F41。

这一块的提示文案曾经有五种状态（等清单 / 缺变量 / 报错 / 清单为空 / 没问题）挤在同一个 `<p>` 里，靠 `textContent` 判断就分不清「还在等」和「结论已经出来了」——点测脚本因此连续跑了 18 秒的循环，最后拿上一轮的文字做了断言（PASS 是假的）。处置是把状态收进 `packages/web/src/runmode.ts` 的两个纯函数：`modelNoteOf(list)` 返回该显示什么（没问题就返回 `null`），`isPendingNote(note)` 判断是不是还在等；界面与点测从此看同一个返回值，6 条单测守住。**「元素还在不在」本身就是一种状态，不能只靠文字内容去猜。**

3.6.6 自定义面试官：一句话补成契约，没有 Key 也能配

五位预设解决的是「计算机岗位」。可这个产品要能给任何行业用，就不能把面试官写死在代码里。 于是自建面试官的产物**不是一段自由文本，而是同一份** `IntentContract`——它和预设共用渲染、共用指纹、共用约束条款， 所以第 2 章讲的「意图可解释、可版本化、可 diff」对自建面试官一样成立。

链路是三段，每段都留了不联网的出口：

1. **描述 → 草稿**（`POST /api/interviewers/draft`，不落库）。模型返回的 JSON 必须过 `interviewerDraftSchema`（名称 1–24 字、目标 8–200 字、手法 2–5 条…），

过不了就不收。用户勾「只用本地规则」时走 `localDraftFromText`：纯规则、确定性、不联网，靠一张措辞表把话翻成手法（说了数字就追口径、说了「参与」就问边界、说了「好评」就问评选范围）。模型这条路失败时**自动退回本地并明说没走模型**，见 D36。

1. **草稿 → 库**（`POST /api/interviewers`）。落 `interviewer` 表（id + version + digest + 契约 JSON），是**全局库**而不是会话表。
2. **库 → 阵容 → 会话。** `POST /api/sessions` 的 `interviewers` 收 id 列表，解析出的 `panel` 写进 `meta.panel`。

契约一旦被某场会话引用就冻结在会话里：后来在库里改了、删了，旧会话的复现与对账仍然成立。

有个坑值得记下来：`resolvePanel` 只能把预算的**三个**字段交给契约。`maxConsecutiveUnanswerable` 是编排层的关停策略，不属于面试官契约；多给一个字段，同一场沙盘就会在「运行」与「对账」两处算出不同指纹，界面把没漂移的沙盘报成「契约漂移」（F42）。 预设不可改也不可删——它们的人设写在代码里，改预设等于悄悄改历史。上限 40 位，够用且防止界面被自己的库拖垮。 为什么不干脆让用户填一段 System Prompt 自由文本？因为那样就丢掉了可解释、可版本化、可对账、可约束这四件事。取舍详见 ADR-0008。

3.6.7 采纳改写：把建议变成一版真能发出去的简历

质询的产出如果只是「你这里讲不清楚」，用户还得自己去改。所以判定之后还有一步：**勾选想采纳的建议 → 确认 → 右栏换成改完的版本 → 导出 PDF / Word。**

这一步有三个容易做错的地方，选法是刻意的：

1. **接口只收 claimId，不收「把 A 换成 B」。**改前改后都从库里那条建议读——如果接口接受任意文本替换，它就等于一个注入面，任何人带着 sessionId 就能把任意内容写进简历。所以 `POST /api/sessions/:id/revisions` 的 body 只有一组主张 id。
2. **每次都从原文重算，采纳记录是集合不是叠加。**先采纳 C1 再采纳 C3，与一次采纳 [C1, C3]，结果**逐字节相同。**这样一来「撤销」不需要反向操作，`DELETE` 清空集合就从原文重算一遍；也就不存在「改了两遍、间距越改越乱」。
3. **改不动的要说出理由。**建议引文在原简历里锚不住（原文被用户改过）、这条主张本来就没有建议、用户点名了不存在的主张——三类都进 `skipped` 并给一句中文原因，界面上直接显示「勾了但没改成：…」，而不是静默少改一处。

导出复用报告那条路：服务端出 HTML，PDF 交给浏览器（ADR-0006），Word 是同一份 HTML + `.doc` 后缀。简历导出与报告导出**分两个渲染器**（`resume-export.ts` / `report-html.ts`）：报告是质询结论，简历是要发给 HR 的东西，混在一起会让简历带上满屏判定徽章。`marks=1` 时才把改动段标绿并附「本版改了什么（N 处）」——默认导出的就是干净的一版。改动坐标用的是 `movedSpans(applied)`：采纳会让后文整体平移，标记位置必须按累计位移重算，不能直接套原文坐标（见 `packages/shared/src/revise.ts`）。

3.6.8 岗位模板库：12 个行业 × 3 个岗位，点一下把料装好

空白投料台对不懂某个行业的人是死路：不知道该喂什么料，也不知道这个工具能问出什么。模板要解决的就是这十秒钟。

模板是**数据不是代码**：36 条 `JobTemplate`（`{id, industry, title, jd, resume, hints, presets, custom}`）放在 `packages/shared/src/templates/`，加一个行业只改数据文件，界面只读、规则不重复实现。三条选法是刻意的：**翻库不落库**（`GET /api/templates` 不写任何表—— 浏览一遍不该往全局面试官库里塞几十位）；**一键采用幂等**（模板自带的那位面试官，id 由 `customInterviewerId(name, template.id)` 派生，同一个模板永远同一个 id，点两次是复用，`created` 让界面说清是哪一种，F50）；**每条都必须留可追问的点**——示例简历刻意保留「下降明显」「参与抢救十余次」这类说法并带具体数字，否则一场质询全是「站得住」，恰好演示不出这个产品在干什么。

字数上下限与推荐阵容进常量 `TEMPLATE_LIMITS`，`templateProblems(list)` 是全库唯一校验入口：测试既拿它验 36 条全过，也拿它验「注入一处毛病会被点名」（F49）。取材合规上不做招聘平台爬虫——BOSS 直聘的 robots.txt 对 `User-agent: *` 写 `Disallow: /*?*`，而职位列表页全带查询参数；36 条模板的 JD 与示例简历全部原创。取舍见 ADR-0011、决策 D42。

3.6.9 岗位要求审阅：1–8 份 JD，两处锚点

上一节解决「不知道怎么喂料」，这一节解决「手里有料，但不知道够不够」。用户可以贴 1–8 份 JD（`POST /api/sessions` 的 `jds`，每份 40–6000 字），服务端把它读成两类东西。

一是一张要求清单（`requirement` 表）。三段链路：`jd-extract` 逐份 JD 并发抽要求（每份一次调用，上限 12 条），`jd-merge` 一次把所有 JD 的要求归并（同一件事写在两份 JD 里算一条，`sources` 记来源），`jd-match` 一次把全部要求和全部主张摆在一起逐条对照，给出「答得上 / 答得含糊 / 简历里没写」。归并和对照各只调一次是权衡后的选择：卡带按提示词指纹寻址，逐条调用会把 149 盘演示卡带再翻一倍，离线演示的成本与「提示词一改就全部失效」的风险都会失控。

二是追问的第二处锚点。对「答得上」和「答得含糊」的要求，追问可以带一个 `requirementId` **同时**带一段 JD 原文引文（`jdQuote`）；要求原文锚不回 JD 的，退回普通追问并在 rationale 里说明—— 宁可少一个锚，不编一个锚。三个刻意的选择：

- **双锚点不需要新机制。**`resolveAnchor(source, raw)` 从一开始就不关心 `source` 是简历还是 JD，

所以「一条追问同时挂简历片段与 JD 片段」只是再调一次同一个函数，双锚点因此与单锚点一样可验证、可回放。

- **「简历里没写」单独成栏，不生成追问。**面试官该追问的是简历里**说了但站不住**的话；

把「简历没写」也变成质问，产品就退化成一份岗位说明书审阅清单，而不是压力测试。

- **空 JD 是合法的。**没有 JD 时整条链路跳过，面试官照各自的契约追问（`jdProblems([])` 返回空数组）。

把「至少要有一份 JD」做成接口错误，纯简历场次就整条路走不通——「还没上传」该不该提醒是界面的事，不是数据校验的事（F55）。

一个只有落库才看得出的问题：双锚点是 `Probe` 的可选字段，第一版只把它写进事件流，业务表里没有对应列。于是重开一场历史会话，双锚点就消失了——报告与界面都查不出「这条追问是照着哪条要求问的」。修法是 schema v7 给 `probe` 补五列（`requirement_id` / `jd_quote` / `jd_start` / `jd_end` / `jd_exact`）并做一次表重建迁移。**「可选字段」不等于「可以不落库」：只要它在界面上显示过，它就是这份记录的一部分**（F54）。

界面按「左简历右 JD」分屏：右栏在简历原文与岗位要求原文之间切换；中栏多一段「岗位要求对照」，每条要求一张卡（要求正文、引文、「为什么这么判」、对应哪条主张），点引文右栏就聚焦到 JD 的那一段—— 和简历引文用的是同一套聚焦机制。取舍见 ADR-0012、决策 D43。

3.6.10 追问深化：把同一场质询读出四种结论

P10 的四项都在**同一份对话记录上换一个角度**：一律不新增判定口径，也一律从同一处算出来。

- **按类别看短板**（`packages/shared/src/shortfall.ts`）。把每条主张的判定按类别聚合，先排欠得最多的类别，

再列出最该补的 3 处。排序与结论文案只在 shared 里写一次，Markdown 报告、可打印 HTML 与界面读同一份—— 否则会出现「报告说最该补 C3、界面排第一的 C5」这种各算一遍的分裂（决策 D47）。

- **追问强度三档**（温和 / 常规 / 挑刺）。只换预算（每主张 2/3/4 轮、每人每主张 1/2/2 次、全场 40/60/80 次），

不换人设：人设一改，两场之间的档案链就断了。档位随会话落库（`session.meta.difficulty`），重开历史会话仍看得出这一场问得多狠。代价是契约指纹随档位变，所以卡带按三档各录了一份（ADR-0014、决策 D46）。

- **补充说明。**用户可以在任何一条主张上手写一句真话，当作这条主张的新证据。它在数据上就是一次**零宽插入**

（`start === end`、`before` 为空串），复用采纳改写的同一条通道——不必为「加一行」再发明一种写操作。它只落那句话本身、不落坐标，插入点由主张的锚点现算（坐标是原文的函数，存下来只会腐烂，见 ADR-0013）。

- **轮到你了。**跑完给出几句用户可以**反问 HR** 的话，每句都必须把依据锚回简历原话或 JD 原文；锚不回的当场丢弃，

在「被丢掉」抽屉里写明理由。回答由沙盘里的求职者 Agent 代答，界面上写明「沙盘模拟，不是真 HR 在答」—— 不然用户会把它当成真实面试答案背出去（ADR-0015）。

四条链路共用一个前提：**结论必须能由输入唯一确定**，所以它们都是纯函数，也都能在零网络下由仓库里的卡带复现。

3.6.11 改前改后对照：把改动摆回上下文里

采纳改写之后，界面与报告都要能回答「到底哪一句被改成了什么」。只把 before / after 一列一列摆出来是不够的：读者看不出这句改动落在简历的什么位置，也不知道前后文是什么。所以并排对照多摆一类行——

- **改动行**：左边是原文那一段，右边是改完的那一段；插入型改写的「原文」是空的，写「（新增一行）」。
- **上下文行**：改动之间那些**没动过**的原文也摆进来，两侧相同，超长时朝改动的方向截断（改动之前留尾巴、之后留开头）。

聚合只写一遍：`packages/shared/src/revise.ts` 的 `sideBySide(resumeText, applied)` 产出这些行，报告（`report.ts` 的三列表格）与界面（`RevisionBar` 的 `data-shot=revision-diff`）都读它——同一份结论两处各算一遍，迟早长出两个版本（F63）。这一节**只在真的采纳过之后出现**（没采纳就是把同一份原文抄两遍），章节编号也跟着走：没采纳时「复现方式」仍然是六（ADR-0016、D50 / D51）。

界面里默认收起，点「并排看改动」才展开：它是核对时才看的东西，不该一直占着采纳栏的地方。

3.6.12 改完再跑一遍：版本对比按文本配对

这套产品的核心承诺不是「体检一次」，而是「改完到底有没有变好」。做法是给会话记一条版本链：`session.parent_session_id`（schema v10）记着「这一版是从哪一场改出来的」，对比时现算，不另存档案表。

难点在于**两场之间的「同一条主张」不是一个能从数据里读出来的事实**：会话内的主张 id 每场都从 C1 重新编号，而用户采纳改写之后，被改的那一句在原文里已经不存在了——文本变了，id 也变了。所以配对只能是估计：`packages/shared/src/compare.ts` 的 `alignClaims` 用 bigram Jaccard 给所有候选对打分，按分数降序贪心一对一，阈值 0.34（真实简历上试出来的：换说法 0.45–0.65，同主语不同事约 0.2）。配不上的单独摆出来（新增 / 消失），不硬塞进某一对里。判定变没变复用短板排序的 `WEAKNESS_RANK` 比大小，**不新写一套「哪个判定更好」**。

结论只算一次：`compareHeadline` 那一句话被 Markdown 报告、可打印 HTML 与界面的「比上次」栏三处共用；报告里它还让后续章节编号整体 +1（章节编号跟着内容走，见 3.6.11）。离线演示因此每种档位组合要跑**两场**（第一场全采纳 → 第二场拿改完的简历再质询），换来的是「没有 API Key 也能看见站得住的从 1 条变成 5 条」（ADR-0018）。

3.6.13 历史仪表盘：只聚合，不引入新判定

历史栏跑到第三场就失效：一列场次看不出是在变好还是在打转。所以历史栏顶上有一句话结论，外加趋势柱、最欠证据的类别、以及「同一份简历跑过几场」。

关键约束是**谁来算**。判定分布与类别短板项目里已经各有一份实现（`verdictCounts` / `categoryShortfalls`），仪表盘直接 import，自己不持有任何「哪个判定更差」的知识——两处各算一遍，哪天口径一改就会分叉，而两边都看着合理（F69）。聚合仍是纯函数（`overview.ts` 的 `overviewOf`），服务端只读库攒数据。

两条口径：追问数**取不到就是 `null`，不猜 0**（猜 0 会让还没跑完的场次把平均值往下拽）；趋势**不足两场就不画**，换一句「要等第二场跑完才看得出来」。空库也返回完整结构，但界面整块不渲染——新用户第一眼该看投料台，不是一排空柱子。窗口上限 200 场，它是性能边界不是分页（ADR-0019）。

3.6.14 单文件打包：断网双击就能看

自己带走有六种形态（报告 md / html / doc，简历 txt / PDF / Word），但**发给别人**是另一件事：对方要判断哪个是哪个，发到微信里基本会散掉；而最需要被传播的那句话（「你简历里这句，撑不住」）恰恰在报告里。于是有一份打包版：一个 HTML 文件，双击就看完整场。

打包不重写报告，而是直接嵌 `renderReportHtml` 的输出（切掉 footer 之前的部分），后面接两节附录：「附一、简历原文（含本版改动）」把采纳过的改动标绿，「附二、这一场是怎么跑出来的」把事件表里八类关键事件（阶段开始 / 抽出主张 / 一轮追问 / 给出判定 / 反推改写 / 轮到你了 / 出问题）翻成人话。同一份事实两套渲染迟早长成两个版本（F63 同族），所以正文只写一遍。

真正的约束不是排版，是**外链**：收件人可能断网，一个在线字体就会让文件变成白纸，而这件事发件人永远看不见。因此「输出里不许出现 `http://` / `https://`」是一条可执行断言（`packages/server/test/bundle.test.ts`），不是文档里的一句话（F71）。时间线里的阶段键名也翻成中文。示例场次整包 24 KB，因此不引入 base64 或压缩（ADR-0020）。

打包函数**不读库**：简历那节在内部用 `applyRevisions` + `movedSpans` 重算，输入只有 `SessionView` 与 `applied`。第一版它去读一个不存在的字段（`view.session.revisedText`），typecheck 当场报错——复用渲染器不等于复用调用方的副作用（F72）。

3.6.15 成长档案：轨迹在相邻两版之间连，不跨版配对

C1 的「比上次」只回答相邻两版；改到第三、第四版时，用户想知道的是**这条我改了几回、现在还站不住吗**。数据面早就齐了：`session.parent_session_id` 把每一版串成链，每场的主张与判定都在库里，缺的只是读出来并配对。

配对只在**相邻两版**之间做（复用 3.6.12 的 `alignClaims` 与 0.34 阈值），再把每一步的配对串成链。跨版直接配对看着更省事，实测会撒谎：第二版把口径补上后相似度约 0.5（相邻配对稳稳配上），第三版再改半句，累积改动让「第一版 vs 第三版」掉到阈值之下，同一条主张被算成「消失 + 新增」两条。两个结果都对，用户没法判断该信哪个，所以只留一个算法（F73）。

`persistent`（改了还在被打回）写死四个条件：最新一版仍在、出现过 ≥ 2 版、一次都没站住、有判定——少任何一条都会开始说谎（改完站住的被算进来、只出现过一版的被算成「反复被打回」、中途消失的说成「还在」）。

链是读 `parent_session_id` 连出来的，不是新表（版本链只在建档那一次写入，结构上长不出环）。schema v10 刻意没给这一列加外键——删掉上一版不该把这一版带走。代价落在读侧：父会话被删之后沿链会撞空，第一版把它当成「这是第一

版」，界面就说「你只有 1 版」，而用户明明记得跑过两版， 只会以为数据丢了。所以「断」是一个字段：`broken` + `brokenAt`（断在哪一场）， 界面照实说「再往前那一场已经被删掉了，轨迹只能从这一版算起」（F74）。

界面做成覆盖层而不是第五栏（四栏在 1600 宽下刚好；这是偶尔回看、不是常驻视角），点了才读库。 窗口上限 12 版：再往回看，主张早改得不像同一句，连出来的轨迹是噪声。见 ADR-0021。

3.6.16 一岗一版：按岗位只做留下与去掉

同一份简历投不同岗位，用户缺的是一个更轻的动作：不重写，只决定去留。 「按这个岗位出一版」把对不上这个岗位的行去掉，其余一个字都不动—— 改写已经有一条独立通道（反推建议 → 采纳 → 改完的简历），筛选若也能改字， 同一段文字就有两个作者，用户从交出去的文件里看不出哪一版是自己确认过的（F75）。

三条实现上的口径：

- **行级归属靠坐标算，不靠模型再判一次。** 一条主张的原文区间落进哪一行，就算那一行承载了它；

采纳过改写时先把坐标按改动长度推到新文本上（改动区间与主张区间完全重合时直接用改后的长度）。

- **「对得上」复用要求对照的结论。** 要求对照已经判过答得上 / 答得含糊 / 简历里没写，

筛的时候前两种算对得上，只有「简历里没写」不算——它是简历里压根没提的要求，没有哪一行可以去。 自己再算一遍的失败方式不是崩溃，而是报告说 4 条对得上、筛出来只剩 2 条，两个都对但不一样。

- **两种「筛不出来」要分开说。** 还没有要求对照时返回原文并说明（回去跑一场）；

一条都对不上时返回原文并拒绝筛（回去补缺口）。二者在用户眼里都是「没筛」，要做的事却完全不同（F76）。

筛过的文本按行重新切段，**一律不画锚点**：坐标全变了，拿原文坐标去画高亮只会画错位置。 结果不落库、每次现算——文字、段数、去掉哪几条都能从原文 + 采纳记录 + 要求对照推出来，三个导出文件都是现算现发。见 ADR-0022。

3.7 工程质量：门禁五道

`npm run verify` 是提交前必须全绿的一道门，它由五件事组成：

顺序	命令	证明什么	当前规模
1	`npm run typecheck`	类型对（`tsc --noEmit`，含各包）	全仓库
2	`npm run test`	逻辑对（vitest）	71 个文件 / 732 条断言
3	`npm run smoke`	**产品能跑**（真起进程、真打 HTTP、真等 SSE）	9 项
4	`npm run build`	前端能构建	vite，48 modules（CSS 30.46 kB / JS 355.23 kB，gzip 107.97 kB）
5	`npm run budget`	**够快**（起服 / 整场回放 / 报告 / 打包的耗时与体积上界）	14 项

第 3 道是 `findings.md` F11 的直接产物：同进程的 `app.request()` 测试全绿，真起服务却第一次写入就报没有表。 **单元测试证明「函数逻辑对」，冒烟证明「产品能跑」——两句话之间隔着一个进程边界，而事故恰好长在边界上。**

除 verify 之外还有三个可选门禁，都做成了命令：

命令	作用	什么时候跑
`npm run shots`	无头浏览器点一遍全流程，出 26 张截图，**控制台有报错即失败**	改了界面之后
`npm run repro`	干净目录 clone → install → verify → 起服跑一场，逐步计时	改复现路径之后
`npm run stats`	量一遍代码规模与测试密度，下面 3.7.1 那张表就是它的输出	加了模块之后
`npm run seed:demo`	重新生成 149 盘离线卡带并自检	改了提示词之后

3.7.1 代码规模与测试密度

模块	源码行	测试行	说明
packages/shared/src	4818	2353	纯函数与数据（含 36 条岗位模板、短板聚合、补充说明、反问依据、并排对照、版本对比、历史聚合、成长轨迹、一岗一版的留与去），测试密度最高
packages/server/src	11246	7067	编排 + IO + 导入解析 + 面试官库 + 岗位要求 + 反问 + 报告三种形态 + 采纳改写 + 版本对比与历史聚合、成长档案接口、一岗一版接口与三件套导出、单文件打包，含脚本化模型夹具
packages/web/src	7469	1938	折叠器、文案、工作室、模板选择器、要求对照、短板与反问栏、并排对照表、「比上次」、历史仪表盘与成长档案抽屉、一岗一版栏（只计 .ts/.tsx，index.css 另 321 行）

模块	源码行	测试行	说明
tools/	3756	597	导出器 / 冒烟 / 截图 / 界面点测 / 复现 / 文档构建 / 零门槛启动器 / 代码规模统计（只计 .mjs，测试目录另计）
合计	**27289**	**11955**	测试/源码 ≈ 0.44

这张表不是手工量的：它是 `npm run stats`（`tools/stats/lines.mjs`）的输出，口径写在脚本注释里（只数行，按路径里的 `test` 目录分源码与测试）。

3.7.2 零门槛入口：双击就能用，判断逻辑可单测

「十分钟复现」是给会敲命令的人写的；第 7 条要求**完全没用过命令行的人也能装起来**。实现是三个入口脚本（`启动.cmd` / `启动.sh` / `装个快捷方式.cmd`）+ 纯函数模块 `tools/launcher/src/plan.mjs`，**不打包成 exe**（打包要本地编译，且我这台机器打包成功不代表别人机器上双击不被拦住，见 ADR-0010）。`launch.mjs` 只碰文件与起进程，判断全在纯函数里—— 因为这类逻辑没法靠人肉点两遍验证：`launcherSteps(...)` 必须是五步、全装好只剩三步（12 条测试，F46）。 两个只有真跑才露出来的细节：快捷方式没给图标就绝不写 `IconLocation`（空串会让图标变白纸）； 启动前先探测 `/api/health`（命中就复用，不撞端口，F47）。实测首次约 20 秒、之后约 2 秒。 仓库里 **0 个 TODO / FIXME / HACK、0 处 `as any`、0 处 `@ts-ignore`**（全仓库 grep 实测）。 console.log 只出现在两个 CLI 入口（serve.ts 与 seed-demo.ts）。

3.7.3 CI：把「在别人机器上还成不成立」也管起来

`npm run verify` 证明的是「在这台机器上、以我的环境为准」是绿的，证明不了两件事：干净检出（Linux、没有本机 Edge、 没有 `D:/CZB` 这个路径）还能不能跑；提示词改过之后卡带是不是已经脱节——后者不红，它的红点出现在评委点按钮的时候。 `.github/workflows/ci.yml` 因此让 ubuntu 跑同一套 `verify` 加一条**卡带漂移门禁**（重跑 `seed:demo` 后 `git diff --exit-code -- fixtures/llm`：seed 逐字节确定，diff 非空即「忘了重录」），让 windows 另跑构建与点测；`e2e.mjs` 里写死的卡带目录与浏览器路径也改成按仓库根反推 + 候选列表（F77）。

- 服务端零构建是整条复现路径的地基，它成立的前提是被实测验证过的，不是查文档查来的。
- 模块按依赖方向切：shared 无 IO、server 不知前端、web 不引 shared（用测试守漂移）。
- LLM 适配层一个接口三种实现，卡带用提示词指纹寻址，缺卡带时响亮报错而不是静默降级。
- 直播与历史共用同一个折叠器，保证「刷新后看到的和刚才看到的是同一场」；门禁五道里真进程冒烟不可替代，性能预算管「够快」。

第四章　可复现性论证

赛题 25% 给「过程可复现性与演进链路」。这一章不讲愿景，只回答三个可核查的问题：

1. **别人能不能在我的机器之外跑起来？** （4.1–4.3）
2. **没有 API Key 能不能看到完整效果？** （4.4）
3. **我凭什么说这些提交是真做的，而不是最后一次性倒进去的？** （4.5–4.6）

4.1 复现路径：两条路，通到同一个界面

路 A：不敲命令（对应第 7 条要求）：装 Node LTS（https://nodejs.org/zh-cn/download）→ 下载 ZIP 解压到**无中文无空格**的目录 → 双击 `启动.cmd`（macOS / Linux 用 `./启动.sh`）。 启动器自己判断该做什么（缺依赖就装、缺前端产物就构建、起服务后轮询 `/api/health` 通了再开浏览器、已有实例就直接复用），第一次约 20 秒、之后约 2 秒；细节与取舍见 3.7.2 与 ADR-0010。

路 B：命令行（开发者与评审的常规路径；`npm run launch` 与双击等价）

```
git clone <仓库地址>
cd crossexam
npm install
npm run preview        # 打开 http://127.0.0.1:8787 ，点「一键示例」，点「开始质询」
```

步骤	需要什么	不需要什么
clone / 下载 ZIP	网络	不需要账号（公开仓库）
install	Node ≥ 22.6（实测 24.14.0）、npm	不需要 pnpm / yarn、不需要编译工具链
preview	磁盘可写	不需要 Docker、不需要 API Key、不需要数据库服务
浏览器操作	任意现代浏览器	不需要装任何客户端

4.1.1 实测耗时（干净目录，`npm run repro` 的输出）

步骤	耗时	说明
git clone	33.3 s	含 149 盘卡带与 26 张截图
npm install	15.0 s	117 个包，来自 npmmirror
npm run verify	18.6 s	类型检查 + 732 条断言 + 冒烟 + 构建
起服 + 跑完一场 + 下载报告	0.8 s	回放模式，46 ms 跑完整场
合计	**70.8 s**	距 10 分钟上限有 8 倍余量

这个表不是估的，是 `tools/repro/repro-check.mjs` 在一个**全新临时目录里 git clone 出来**的仓库上逐步计时得到的。 同一台机器多次预演落在 34–121 秒之间：磁盘缓存冷热（`clone` 2.8 s 到 24.6 s 都出现过）与机器当时在不在忙都会影响， 这张表记的是最近一次完整预演（70.8 s）。最慢的那一次是 120.8 s，机器同时在跑别的任务时测的，那才是诚实的区间上界。写文档时的第一条原则是：**复现耗时必须是实测数据，且必须由命令生成，不能手写**（决策 D16）。

4.2 为什么没有原生依赖

依赖	选择	如果换成常见的替代品会怎样
数据库	`node:sqlite`（Node 内置）	better-sqlite3 需要 node-gyp + Python + VS Build Tools，Windows 上失败率极高
服务端框架	Hono（纯 JS，零依赖链）	Express 也行，但 Hono 自带 `streamSSE` 且体积小
校验	zod（纯 JS）	—
.env 载入	`process.loadEnvFile`（Node ≥ 20.12 内置）	dotenv 会多一个包，且本项目只需要一行
浏览器驱动	系统 Edge/Chrome + CDP + Node 全局 WebSocket	Playwright 会下载 200 MB 浏览器
文档渲染	自写 md2html（零依赖）	pandoc 需要单独安装
截图	CDP `Page.captureScreenshot`	—

上表每一行都能对应到 `AGENTS.md` 第 6 节那条约束：「引入需要本地编译的原生依赖会毁掉 10 分钟复现，需要 ADR 才能破例」。 至今没有破例。

4.3 三个「静默失败」的坑，以及它们如何变成规则

可复现性的敌人往往不是「跑不起来」，而是「**看起来跑起来了，其实用的是别的东西**」。本项目踩过三个：

坑	现象	变成的规则
说明书写了 `cp .env.example .env`，程序从没读过它	填了 `CROSSEXAM_MODE=live` 仍是回放，配置静默失效	启动横幅必须打印「已载入哪个 .env」或「没有 .env」
端口上挂着旧进程	live 实测报「0 分片」，其实测的是流式功能落地**之前**的旧服务	一次性实测起服务前必须自检端口为空，并核对写入的是自己的临时库
通用 .gitignore 模板的 `bin/` 段	源码被静默忽略，P0 提交漏掉了导出器 CLI	忽略规则要**正反各测一遍**：密钥被挡住 + 源码没被挡住

第二、三条的完整复盘在 `findings.md` F22 与 F6/F10。它们共享同一个教训：

> **退出码为 0 不代表事情办成了。凡是「静默忽略」的机制，都要在事后做一次正面确认。**

4.4 离线回放：没有 Key 也能看到完整效果

4.4.1 卡带机制

回放模式下，每一次模型调用的「问题」被哈希成一个 24 位指纹，**答案**就存在以该指纹命名的 JSON 文件里：

```
fixtures/llm/
├── 0a3f...c2.json    extract 阶段的回答
├── 1b7e...d9.json    probe 阶段某位面试官的回答
└── ...               共 149 盘
```

指纹只对请求的五项内容做哈希（system / messages / temperature / maxTokens / json）， 因此**改了提示词，指纹就变，旧卡带自然失效并响亮报错。**这既是一个约束，也是一道门禁（4.4.3）。

4.4.2 149 盘卡带覆盖了什么

阶段	卡带数	说明
extract	4	抽主张：第一场 + 第二场，各按三档追问强度的提示词差异分开录
jd-extract / jd-merge / jd-match	各 1 / 1 / 4	读一遍内置示例 JD：抽要求 → 归并 → 与主张逐条对照
probe	78	3 位面试官 × 三档追问强度 × 两场（每场轮数不同）
answer	25	两场加起来 15 条追问，各一次作答，跨档合并去重
verdict	20	两场各 5 条主张 × 三档追问强度（追问记录进提示词，档位不同提示词就不同）
suggest	12	4 条需要改写的建议 × 三档改写风格（「站得住」的那条跳过；第二场五条全站得住，不产生建议）
counter	4	一轮「轮到你了」的合成反问，跨档合并去重

跑完一场离线演示的权威数字（`.tmp/doc-stats2.mts` 直接调 `runAndPersist` 实测，常规档）：

指标	值
耗时	46 ms
轮数 / 主张 / 追问 / 判定 / 建议	3 / 5 / 10 / 5 / 4
被锚定机制拦下的主张	1
判定分布	站得住 1 · 表述过度 1 · 证据缺失 2 · 无法回答 1
token	输入 27,050 · 输出 4,122 · 思考 724（合计 31,172）
反问	4 句（依据 JD 2 · 依据简历原话 2）
每位面试官追问数	tech 4 · hr 3 · hiring_manager 3
岗位要求对照	7 条要求：答得上 1 · 答得含糊 3 · 简历里没写 3
模型调用	33 次，回放 33 次（一个网络包都没发）
事件	24 条（阶段事件可断线续传，分片不进事件表）

4.4.3 卡带是合成的，而且必须被证明是合成的

这 149 盘卡带由 `createDemoScriptedClient` 用**确定性脚本**生成，不是真实模型的输出。这一点在文档里、在 `fixtures/README.md` 里都写明，并且有三重可核查的痕迹：

痕迹	怎么核查
每盘卡带的 `model` 字段都是 `scripted-demo`	打开任意一个 JSON 就能看到
`recordedAt` 是固定常量 `2026-10-26T00:00:00.000Z`	因此重跑 `npm run seed:demo` **逐字节相同**，git status 干净
usage 是按字符数折半的估算值，不是计费数据	生成器里有明确注释

为什么必须这么做？因为**卡带是要提交进公开仓库的。**真实模型输出 + 真实简历 = 隐私泄漏。 因此 `fixtures/README.md` 里写了一条红线：只允许用示例简历录制卡带。

4.4.4 提示词漂移门禁

卡带最大的风险是「代码改了提示词，卡带没重录，演示静默变味」。守住它的是一条测试：

```
packages/server/test/demo-cassette.test.ts
  用仓库里已提交的 fixtures/llm 起一个真实 app，
  POST /api/sessions（useDemo）→ POST /run?stream=0
  断言：200 / 主张 5 / 被拦 1 / 判定含 unanswerable 与 solid / 建议 ≥ 1 / 反问 4 / 双锚点非空
```

这条测试跑的是**已提交的素材**，因此任何人改了提示词而忘了 `npm run seed:demo`，提交门禁立刻变红。 它同时也是一份「离线演示确实能跑完」的回归证据。

4.4.5 想联网跑真模型怎么办

```
cp .env.example .env       # 填 LLM_BASE_URL / LLM_API_KEY / LLM_MODEL
# .env 里设 CROSSEXAM_MODE=live
npm run start
```

服务启动横幅会明确打印当前模式与「是否已载入 .env」。实测在 DeepSeek 上跑通（见 5.5 节）。

4.5 演进链路：250 余次提交是怎么来的

4.5.1 规则写在仓库里

`AGENTS.md` 第 2 节把赛题的提交要求变成了可执行的工程规则：

规则	内容
粒度	一个提交 = 一个可独立说明的改动。禁止 `git add -A && git commit` 式大杂烩
判据	提交前先问：**这个提交对应哪一次 AI 对话？** 答不上来就说明粒度不对
格式	Conventional Commits + 中文简述（不超过 50 字）+ 正文写「为什么这么改」
署名	**禁止** `Co-Authored-By` 等 AI 署名尾注（GitHub 会把它们解析成账号并计入贡献者列表）

4.5.2 阶段与提交的对应

阶段	内容	提交数（约）
P0	仓库初始化、工程约定、DSH 会话导出器	5
P1	领域内核：锚定 / 切分 / 预算 / 契约 / schema；LLM 适配层	17
P2	五阶段编排、存储、HTTP/SSE、报告、示例简历、冒烟	15
P3	前端：包骨架、HTTP 契约、事件折叠、三栏界面、单端口托管	7
P4	截图器、意图契约可见、复现预演、README 复现指南、流式吐字	30+
P5	技术文档、Prompt 链刷新、发布清单	8
P6–P7	判定口径 / 思考可视化 / 报告三形态 / 12 项可用性优化（导入、工作室、采纳改写、零门槛启动）	60+
P8	岗位要求审阅：1–8 份 JD、双锚点、schema v7 表重建	15
P9	行业模板库：12 个行业 × 3 个岗位，一键采用幂等	10
P10	追问深化：按类别看短板 / 追问强度三档 / 补充说明 / 轮到你了	30+

4.5.3 一个具体例子：一次 Bug 修复对应哪一次对话

以「修改建议全部失败」这个 bug 为例，它对应的提交链是：

```
c8a6e90 fix(shared): 修改建议不再要求模型自报主张编号
```

提交正文写的是「为什么」：提示词从未要求模型输出 claimId，而 schema 把它列为必填； 合成卡带恰好写了这个字段，于是离线全绿、真实模型全红。这类信息只有写进提交正文才留得下来。

4.6 Prompt 链：过程证据不是事后补写的

赛题要求提交「≥3 个核心功能迭代的完整 Prompt 链（提问、AI 建议、如何引导修 Bug）」。

本项目的做法是**从第一行代码起自动导出**：

环节	实现
原始数据	DSH 把每一次会话写成 zstd 多帧压缩的 JSONL，落在 `%APPDATA%\dsh-desktop\harness\sessions\<工作区>\<会话>\session.v4.jsonl.zstd`
解析	`tools/dsh-export` 逐帧解压（`zstdDecompressSync` 只解第一帧，必须扫描魔数 `28 B5 2F FD`），按 turn 组织成时间线
脱敏	自动识别 6 类密钥格式（OpenAI / Anthropic / GitHub / AWS / Bearer / KEY=value 赋值），命中即替换
过滤	只把 `source.kind === 'user'` 的消息当真人提问，系统注入（runtime-context / skill-catalog / plugin:hindsight / time-context / agent-instructions）全部丢弃
分页	超过 40 万字符自动按**条目**边界切分（不是按轮次，因为单轮可能 144 万字符），每份都能在网页上直接渲染
产物	`docs/prompt-chain/` 下 30 份分片，共约 8.0 MB，覆盖整个开发过程

这条链带来三个别的方式给不了的性质：

性质	含义
不可事后美化	快照是会话日志的直接产物，改一个字就会和日志对不上

性质	含义
包含失败	走错的路、被推翻的方案、修 bug 的过程都在里面，不是只挑成功的展示
可复跑	`npm run export:prompt` 一条命令重新生成，不需要手工整理

4.7 本章要点

- 复现路径有两条：双击 `启动.cmd`（零门槛）或四条命令（70.8 秒，实测，由 `npm run repro` 生成，仍有 8 倍余量）。
- 零原生依赖是硬约束，至今没有破例。
- 离线回放让「没有 Key 也能看到完整效果」成立，149 盘合成卡带 + 一条漂移门禁守着它。
- 提交粒度规则写在仓库里，250 余次提交每一次都能对应到一次具体的开发动作。
- Prompt 链是会话日志的直接产物，自动导出、自动脱敏、自动分页——过程证据不是作文。

第五章　实测证据

这一章只放**可复跑的数字**。每条结论后面都标了它是怎么测出来的；凡是无法复跑的观察（例如「真实模型偏保守」），都会明确写成观察而不是结论。

5.1 门禁现状

```
npm run verify
  1/5 typecheck   tsc --noEmit（根 + shared + server + web）
  2/5 test        71 个测试文件 / 732 条断言
  3/5 smoke       9 项真进程冒烟
  4/5 build       vite 8.3.5 / 48 modules / CSS 30.46 kB / JS 355.23 kB（gzip 107.97 kB）
  5/5 budget      14 项性能预算（起服 285 ms / 整场回放 93 ms / 打包 22 KB / JS gzip 105 kB）
  exit 0
```

测试分布：

包	测试文件	覆盖重点
shared	18	锚定的四种拒绝、归一化映射、预算五道闸门、契约渲染确定性、schema 解析、自建面试官草稿（18 条）、采纳改写与标记坐标（11 条）、岗位模板库 36 条的合规与指纹（8 条）、岗位要求的锚定与归并（14 条）、短板的分组排序与结论（11 条）、追问强度三档只换预算（10 条）、补充说明的长度与插入点（10 条）、反问依据的锚定（12 条）、并排对照的上下文行（5 条）、改写风格三档的文案与取值（6 条）、两场主张的相似度配对与判定位移（17 条）、历史仪表盘的聚合与趋势窗口（11 条）、成长档案的相邻配对与 persistent 口径（12 条）、一岗一版的留与去与坐标推算（13 条）
server	28	九阶段编排、闸门顺序、SSE 收尾、迁移（含 v6→v7 表重建与 v8 / v9 加表）、卡带、流式、阶段路由、报告、简历导入（PDF / docx / 文本共 11 条）、运行模式与模型清单、面试官库与契约优化（9 条）、采纳改写与三种导出（14 条）、补充说明的落库与采纳插入（14 条）、岗位模板库的只读与幂等采用（6 条）、多 JD 的抽取 / 归并 / 对照与双锚点落库（6 条）、三档预算与档位落库（7 条）、反问的锚定与两份报告（5 条）、报告里的改前改后对照（3 条）、改写风格的落库 / 下发 / 换档不动指纹（7 条）、版本对比接口与两份报告的「比上次」（11 条）、历史仪表盘接口与路由顺序（6 条）、单文件打包的无外链与附录（6 条）、成长档案接口与版本链断裂（7 条）、一岗一版接口与三件套导出（9 条）
web	18	文案漂移与判定口径、高亮切分（含「聚焦压住已改写段」）、事件折叠（直播 vs 历史）、流式分片解析、报告网址、配色主题、新手教程文案、工作室常量与 shared 对账（8 条）、采纳栏状态（10 条）、模型提示文案的四种态（6 条）、模板分组与采用提示（8 条）、JD 列表编辑（7 条）、要求对照的派生值与分组（9 条）、短板派生值（5 条）、反问事件折叠（4 条）、「比上次」的四种状态与逐条位移文案（6 条）、仪表盘柱形几何与文案（9 条）
tools	7	分页、zstd 多帧、脱敏、Markdown 渲染、零门槛启动器（版本判定 / 该走哪几步 / 快捷方式脚本，共 12 条）

测试文件总数 18 + 28 + 18 + 7 = 71；`npm run e2e:ui` 另有 **157 项**真浏览器行为断言（不进 verify，因为它要一台装了 Edge/Chrome 的机器）。

5.2 三条最有说服力的测试

5.2.1 直播与历史必须给出同一个界面

`packages/web/test/state.test.ts` 把同一串 15 个事件喂给两条路径：

```
路径 A: sandboxReducer + {type:'event'}        （模拟 SSE 直播）
路径 B: stateFromHistory(events)               （模拟刷新后从库里读）
断言: claims / probes / budget / errors / interviewers / rejectedClaims / eventCount 完全一致
      只有 phase 不同（'running' vs 'done'）
```

这条测试守的是产品承诺「刷新后看到的和刚才实时看到的是同一场」。它一共有 17 条断言， 其中还覆盖了：预算事件让主张关停、作答报错在卡片上显示、空追问轮自己补提示、未知 claimId 与重复 probeId 被丢弃、致命错误把 phase 置为 failed。

5.2.2 提示词必须是确定性的

`packages/server/test/orchestrator-extract.test.ts` 有一条：

```
同一个输入渲染两次提示词 → 逐字节相同
```

理由不是洁癖：卡带按**提示词指纹**寻址，提示词抖一字节，整盘离线回放就失效。 因此所有阶段的提示词全部是纯函数，不含时间戳、不含随机数、不依赖 `Object.keys` 的顺序。

5.2.3 锚定不采信模型给的坐标

同文件另一条：给模型一个**错误的 start/end**，但引文是对的， 断言最终锚点是程序用 `indexOf` 重新定位出来的区间。 这条把「证据锚定」从一句口号变成了可验证的行为。

5.3 全接口验收：78 项（一次性脚本，端点此后又长了一倍）

`.tmp/api-matrix.mjs`（一次性验收脚本，自起服务、自建临时库）覆盖：

> 诚实的边界：这份脚本**没有进仓库**（它在 `.tmp/` 下），测的也是当时的端点集。此后又加了简历导入、 面试官库、岗位模板库、采纳改写与多 JD 这几组接口，而它们现在的覆盖在 `npm run test`（server 24 个文件） 与 `npm run e2e:ui`（157 项真浏览器断言）里。把全接口矩阵做成**可复跑的命令**列在 P13，不在这里假装它还新鲜。

类别	项数	例子
健康 / 示例 / 契约	12	契约指纹格式、`?panel=tech,cto` 返回 400 并列出可选值
建档错误分支	4	简历太短（少于 30 字）返回 400 且中文提示
完整跑一场	18	轮数 3、主张 5、追问 10、判定 5、建议 4、被拦 1、usage 输出 2,267
落库校验	9	事件 18 条且 seq 连续、`?from=10` 续传 8 条、账本 calls=29
报告	6	四个章节齐全、Markdown 可直接下载
SSE	5	含 `stream` 分片且**分片不进事件表**
静态托管	4	首页 200、SPA 深路径回退、未知接口中文 404

结果：**78 PASS / 0 FAIL**。

5.4 真浏览器实测：控制台 0 报错

不装 Playwright，用系统 Edge + CDP + Node 自带 WebSocket 驱动（`tools/ui-shots/shots.mjs`）：

项	结果
截图	26 张，全部由命令生成（含新手教程、浅色配色、面试官工作室、采纳改写、岗位模板库、岗位要求对照、按类别看短板、追问强度、补充说明、反问清单、改前改后对照、成长档案与一岗一版）
控制台	**0 条报错 / 0 条警告**（收 Runtime.exceptionThrown、consoleAPICalled 的 error 与 warning、Log.entryAdded）
流程	点「慢放」→「一键示例」→「开始质询」，跑到判定与建议全部出现
界面数字	调用 33 次 · 回放 33 · token 31,172 · 事件 24 · 追问 10
与后端一致性	界面判定条数与服务端 `verdicts` 条数一致

截图清单（`docs/screenshots/`）：

图	内容
01-intake.png	空状态：四条机制逐条说明 + 意图契约三条 pending

图	内容
02-demo-loaded.png	载入示例简历
03-running.png	直播中：三位面试官同时追问
04-live-output.png	**实时输出栏：模型正在写的人话**（原始输出是 JSON，界面已还原）
05-thinking.png	**同一栏的「思考 + 输出」两行**：斜体是思考分片，正下方是正文分片
06-done-top.png	跑完总览
07-verdicts.png	判定卡片，含「这条判定不是模型直接给的」
08-resume-focus.png	点引文后右栏聚焦到「第 81–108 字」
09-history.png	刷新后从历史恢复
10-contracts.png	意图契约摊开 + 徽章「与运行时一致 · 指纹 b2171c82」
11-system-prompt.png	该面试官实际拿到的 System Prompt 原文
12-help.png	第一次打开自动弹出的新手教程：四步上手、三种模式对照表、隐私口径
13-light.png	**浅色配色**：白天/投影仪/打印稿上看得清；判定卡片里带「为什么这样判」与「判据展开」
14-report.png	**服务端渲染的可打印报告**：元信息表、过程说明、带判定配色的主张与判定——PDF 就是它经浏览器打印得到的
17-adopt.png	**采纳改写后的右栏**：「改完的简历 470 字 · 改动 4 处（绿色）」+ 已改/待定/改不动/本次勾选四枚计数 + 三个导出入口（.txt / PDF / Word）
18-templates.png	**岗位模板库**：12 个行业 × 3 个岗位，点一下把岗位名、JD 与示例简历（258 字）一起填好，并把模板自带的面试官装进阵容
19-requirements.png	**岗位要求对照**：中栏按「答得上 / 答得含糊 / 简历里没写」分三组，每条要求一张卡（要求正文、引文、「为什么这么判」、对应哪条主张）；右栏在简历原文与岗位要求原文之间切换，点引文聚焦到 JD 的第 28–48 字
20-shortfall.png	**按类别看短板**：同一份判定换个角度摆——结论句 + 四行类别（各欠几条、欠在哪个判定上）+「最该先补的 3 处」，点一下跳回简历原文
21-difficulty.png	**追问强度三档**：挑刺档选中时，契约卡片上的预算与指纹同时换掉（4 轮 / 每人 2 次 / 全场 80 次 · 指纹 cf9c6457）
22-supplement.png	**补一句真话**：用户手写的一句事实挂在主张卡片上（不写进简历原文），点「确认采纳」时它才作为新的一行进简历
23-counters.png	**轮到你了**：4 句可以反问 HR 的话，每句带「依据岗位要求 / 依据简历原话」徽章与可点的引文，回答下注明「沙盘模拟，不是真 HR 在答」
24-diff.png	**改前改后对照**：采纳之后点「并排看改动」，每条改动一行——左边是简历原文里的那一段，右边是改完后的那一段；改动之间没动过的原文也作为上下文行摆进来，所以看得出改动落在什么位置

5.5 真实模型实测（DeepSeek，live 模式）

这一节的意义是：**证明离线演示不是靠卡带撑起来的空壳**，接上真模型确实能跑。

5.5.1 端到端结果

项	值
模型	deepseek-chat（OpenAI 兼容协议）
一场耗时	20.0 s
主张 / 追问 / 轮数 / 建议	10 / 18 / 3 / 9
token	输入 47,941 · 输出 8,355 · 缓存命中 7,424
判定	10 条「证据缺失」（判定口径调整后的实测，见 5.6 第 5 条）
被锚定机制拦下的主张	0（真实模型的引文质量比预期好）

5.5.2 真实追问的质量抽样

下面这条是真实模型对「首屏加载从 2.4s 降到 0.8s」的追问，未经任何修改：

> 2.4s 和 0.8s 这两个首屏加载数字是怎么测出来的——用什么工具、在什么网络条件和设备上、取的是几次采样的什么统计口径?

求职者 Agent 的回答（同样未经修改）：

> 这个……简历里只写了「首屏加载从 2.4s 降到 0.8s」这个结果，具体用什么工具测的、什么网络条件和设备、采样几次取什么统计口径，简历里没有写，我这边没法给你具体细节。

这一问一答就是整个产品的价值主张：它不是「AI 帮你写简历」，而是「AI 找出你答不上来的那句」。

5.5.3 真实模型的流式分片

live 模式下的一场实测：**5,814 个分片 / 29 路 channel / 0 片进入事件表 / 21 条阶段事件。** 接上思考模型（`CROSSEXAM_REASONING_MODEL=deepseek-reasoner`，只路由 verdict）之后再测一场：**2,355 片思考分片 / 8 路 `verdict:*` 通道 / 账本 `reasoningTokens` > 0 / 整场 22.7 s**—— 思考与正文分走两个 `kind`，但同样不进事件表。 这组数字同时证明了三件事：流式真的在流、分片确实被隔离在事件日志之外、阶段事件的规模稳定在二十条左右。

5.5.4 两条诚实的观察（不是结论）

观察	说明
真实模型抽的主张比合成脚本多	361 字简历抽 8–10 条，合成脚本固定 5 条；真实模型还会把「2023.06 - 2025.03」这类时间线也抽成主张
判定口径调完之后，「无法回答」几乎不再出现	求职者 Agent 只依据简历作答，它天然说不出「我不会」，所以「无法回答」本就该是少数；数字类主张更容易落在「证据缺失」（简历没写口径，改简历即可）。代价是区分度下降：这一场 10 条判定全是「证据缺失」

5.5.5 全链路真机验收：真浏览器 + 真联网 + 用户的真实 PDF 简历

上面几节测的是单个环节。最后做了一次**端到端**验收：`.tmp/live-full-all.mjs` 真起服务、真调 DeepSeek、 把 `C:/Users/xinyi/Desktop/第三版简历.pdf` 拖进导入框（解析出 1006 字），再用真浏览器把从投料到导出报告的每一步都点一遍。

轨道	形态	结果
回放	`npm run e2e:ui`（无头 Edge）	**157/157**，控制台 0 报错
联网 + 真实简历	无头 Edge + 真 API + PDF 导入	**32/32**，整场 19–28 s
出图	`npm run shots`	26 张，控制台 0 报错

联网那一场：12 条主张全部锚定 / 12 条判定 / 18 次追问 / 3 轮 / 8 条建议，「改 8 处 1209 字」， 其中 1 处改不动并写出了原因；报告 Markdown 16,326 字符、可打印 HTML 6,191 字符、Word 6,108 字符。 打开思考模型后再跑一场，思考分栏最长一次读到 **221 字**——注意这个数字是 500 ms 轮询采样取的最大值， 只在某一瞬间读一次必然为 0，因为思考分栏只在 verdict 阶段出现。

这次验收抓到的四个缺陷全在**脚本**里（隐藏的 `type=file` 抢到了 `input[0]`、残留 Edge 占着调试端口、 `waitText` 抓到 verdict 中间态导致库里还是 0 行、`view.verdicts` 的字段形状猜错）， 而唯一的产品问题也正是「等待写法不可靠」的同源问题——过程态与结论态共用一个元素（F48、D41）。 **测试脚本的可靠性和产品的可靠性是同一种能力；脚本假 PASS 和产品真 BUG 一样要当缺陷处理。**

5.5.6 P10 四项追问深化：每一项都有自己的界面断言

P10 之后 e2e 从 88 项涨到 **117 项**；P11 的 B2 加了 4 项、B1 加了 5 项，此后 C1 版本对比、C3 单文件打包、P12 成长档案与 P12 一岗一版又各补了几条，现为 **157 项**。新增的全是「界面读出来的结论必须与服务端算出来的一致」，不是「按钮存在」：

项	界面断言（节选）	实测
按类别看短板	组数 = 判定过的类别数；名单条数 = min(短板数, 3)	4 组 / 4 个类别；名单 3 条 / 服务端 4 条短板
追问强度三档	换档后预算与契约指纹都变，切回来必须回到原来那个指纹	042b385f → cf9c6457 → 042b385f
补充说明	存下之后编辑区收起，点「改一句」才重新出现；删掉后卡片回到干净态	存 → 收起 → 改 → 删
轮到你了	引文数 = 服务端反问数；两种依据都标出来源；点引文那一侧原文聚焦到依据那段	4 句 / 2 句依据 JD + 2 句依据简历 / 第 81–108 字

三档卡带另有一条服务端测试守着：温和 / 常规 / 挑刺三档在**零网络**下都能跑完，且预算真的流进了契约（每主张 2 / 3 / 4 轮，每人每主张 1 / 2 / 2 次）。

5.6 五个在实测中抓到的真 Bug

下面五个 bug 都不是设计阶段发现的，是**真跑起来才暴露**的。它们比任何架构图都更能说明这套工程是真的在运转。

序号	现象	根因	为什么之前没抓到
1	真实模型下 9 条修改建议全部失败	schema 要求 `claimId` 必填，提示词从未要求输出它	合成卡带恰好写了这个字段，把矛盾完整掩盖
2	同进程第二场会话 500	claim 表全局主键，而主张编号每场从 C1 重新开始	每个测试都只跑一场
3	真起服务第一次写入报 `no such table: session`	建表靠调用方显式调 migrate，测试都调了、真进程没调	同进程 `app.request()` 测试不经过启动路径
4	live 实测「0 分片」	端口上挂着**流式功能落地之前**的旧进程	没有验证「测的是谁的进程」
5	判定徽章与模型写的理由互相矛盾	代码级收敛把「全体未答」一律改判「无法回答」，吃掉了模型判的「证据缺失」	合成卡带的作答脚本恰好都答得上，离线演示永远不触发这条规则

每一个都变成了规则或门禁：

Bug	变成的规则
1	给模型输出造夹具时，唯一真相是**提示词里的输出要求**，不是 zod schema（F23）
2	复合主键 + 迁移冻结在自己时点（F24）
3	`openDatabase` 连接即建表；门禁加入真进程冒烟（F11）
4	一次性实测起服务前必须自检端口为空、核对写入的是自己的库（F22）
5	代码级收敛只做「防过于乐观」，责任归属交回模型；两档判据写成可判别的「责任在谁」（F31）

5.7 本章要点

- 门禁五道：类型、逻辑、**产品能跑**、能构建、够快。第三道不可替代，第五道让「沉默的性能退化」变成红灯。
- 界面点测 157 项全绿；真浏览器 26 张截图、控制台 0 报错；另有 78 项一次性全接口验收（脚本未进仓库，见 5.3）；

报告三种形态另有真机验收（`.tmp/report-check.mjs`，12/12）：HTML 经 Edge 打印得到 438305 B / 6 页 PDF，界面三个按钮分别指向 `.md` / `.html?print=1` / `.doc`。

- 真模型跑得通：20 s、10 条主张、18 次追问，追问质量可直接引用于演示视频。
- 五个真 bug 都变成了规则，而不是被悄悄修掉——这才是「演进链路」的实质。

第六章　局限、取舍与后续工作

一份技术文档如果只讲做成了什么，它的可信度反而更低。这一章写清楚：**什么没做、为什么没做、如果继续做会先做哪一件。**

6.1 已知局限

#	局限	影响	现状
1	求职者 Agent 只依据简历作答，不使用用户的真实记忆	它答不上来的问题，用户本人**可能**答得上来	刻意如此：测的是「简历这句话能不能自证」，不是「你本人会不会」；报告里也写明
2	判定区分度不足：真实模型下几乎全判「证据缺失」	看不到「表述过度 / 与原文矛盾 / 无法回答」这些信息量更大的档位	口径已修正为「责任在谁」（见 2.6.1）；但求职者 Agent 只依据简历作答、天然说不出「我不会」，所以「无法回答」稀少是结构性的
3	追问策略依赖单一模型的角色扮演	三位面试官的提问风格差异不如真人明显	契约层已把差异结构化（tactics / forbidden 各不相同），但同一模型扮演多个角色仍有同质化倾向
4	只支持中文简历	英文简历的锚定与切分未验证	锚定逻辑本身与语言无关，但 segment 的小节识别按中文标题写死

#	局限	影响	现状
5	当初判断「解析 PDF 会引入原生依赖」，与「10 分钟复现」冲突	一度只能粘贴纯文本	✅ 已推翻：纯 JS 的 `unpdf` 出现后这条不再成立，现支持 PDF / Word / 文本导入，字节不落盘（ADR-0007）
6	单机单用户，无鉴权	不能直接部署到公网	产品定位是本地优先工具，简历属隐私数据，**不上传任何第三方存储**

6.2 三个明确的取舍

6.2.1 抄一份文案，而不是拆包

web 不 import shared（shared 经 util.ts 依赖 `node:crypto`），代价是判定标签与人设文案要抄一份。正确做法是把 shared 拆成零依赖 core + 带 IO 的 adapter，但那是一次全仓库重构；本项目用**漂移测试**（`toBe` 断言同一个对象）替代，把风险压到「测试红了才发现」，而不是「重构期间功能停摆」。

6.2.2 合成卡带，而不是录真实模型输出

真实模型输出 + 真实简历 = 隐私泄漏，而卡带要提交进公开仓库。因此演示卡带由确定性脚本生成， 并用三重痕迹标明是合成的（model 字段、固定 recordedAt、估算 usage）。 代价是离线追问质量不如真实模型（合成脚本 5 条主张，真实模型抽 8–10 条）；补偿是把真实实测的数字与追问原文写进 5.5 节，两者都能被核查。

6.2.3 分片不落库

流式分片走 SSE 但不进事件表，代价是刷新后看不到「刚才正在写的字」；换来回放不被几万条分片拖慢、日志不吵， 而且「能断线续传的只有阶段事件」这条边界很清楚（ADR-0004）。

6.3 如果继续做，先做这三件

优先级	事项	为什么是它
1	让候选人 Agent 能说「我不会」，而不只是「简历里没写」	根治 6.1 第 2 条的判定区分度问题：现在它只能引用简历，所以「无法回答」结构性稀少
2	支持英文简历	锚定逻辑已与语言无关，只需放宽 segment 的小节识别
3	把 shared 拆成 core + adapter	消除抄文案的技术债

原表里的另外两件——追问阶段可补一句事实、报告按主张类别统计——已在 P10 落地（见 3.6.10）。

这张表是「技术上最先该补的」；「产品上还能加什么」见 候选功能清单（六组二十余项，每项写明解决谁的问题、大概几小时、值不值得做）。

6.4 结语

这个项目想做的一件事，用一句话说就是：

> **在简历投出去之前，先让三位不同的面试官把它拆一遍，并且告诉你哪一句你答不上来。**

技术上它试了三件不太常见的事：

1. **把「提问必须有证据」做成程序闸门**（不是提示词里的请求）——幻觉式提问在物理上进不来；
2. **把「追问次数」做成不可变账本**（不是模型自己数数）——死循环在设计上不成立；
3. **把「过程证据」做成会话日志的自动产物**（不是事后整理的文档）——250 余次提交、34 份 Prompt 链快照与本文档里每个数字都可追溯。

第三件事也是对赛题「过程可复现性」那条 25% 权重最直接的回答：过程不是事后描述的，是仓库里一条命令就能重新导出的。

附：本文档自身的可复现性

本文档由 `npm run docs:pdf` 从 `docs/tech/*.md` 生成：零依赖 Markdown 渲染（`tools/docs/md2html.mjs`）→ 无头 Edge 打印（`tools/docs/build-doc.mjs`）→ PDF；构建时统计页数，超过 30 页直接失败（赛题上限）。